Maestría en Inteligencia Artificial y Gestión de Datos para Finanzas, Economía y Negocios
Universidad Católica Boliviana - Octubre/Noviembre/Diciembre 2026

Aprendizaje Profundo I

Rolando Gonzales Martinez, PhD

Investigador postdoctoral

Iniciativa de Pobreza y Desarrollo Humano (OPHI)
Universidad de Oxford (UK)

Fellow postdoctoral

Centro de Estudios Apocalípticos y Postapocalípticos Käte Hamburger

Universidad de Heidelberg (Alemania)

Introducción

Matriz X y vector Y

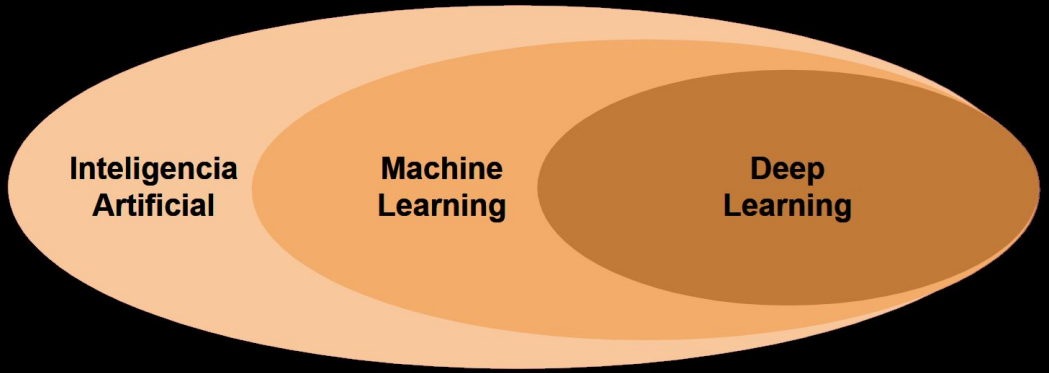
$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Nn} \end{bmatrix} \qquad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Machine learning (aprendizaje automático)

Rama de la inteligencia artificial que tiene como objetivo construir modelos matemáticos que tienen como objetivo:

- Aprender a resolver una tarea
- Aprender a estimar correctamente una variable objetivo
- Utilizar datos contextualizados previos para inferir valores futuros de la variable

El contexto se expresa mediante características (features)



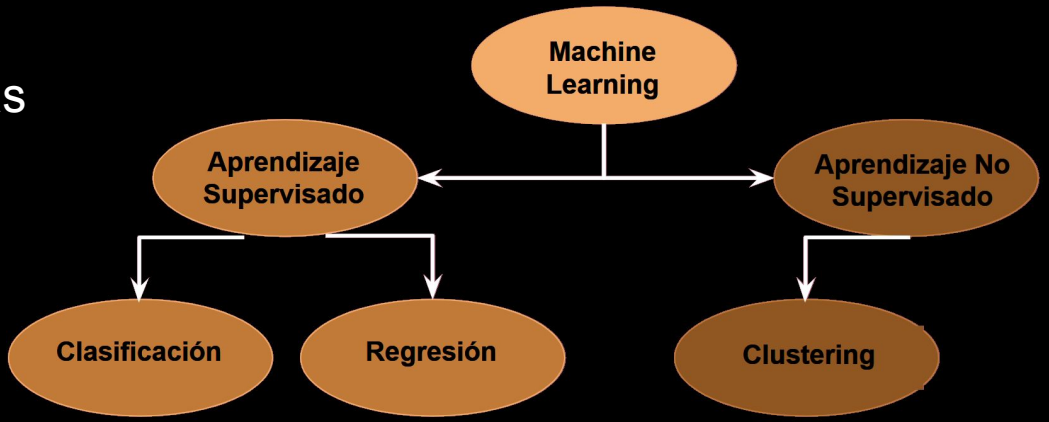
Aprendizaje supervisado y no supervisado

Aprendizaje supervisado:

- Los datos son etiquetados (ground-truth)
- Clasificación, regresión, ordenamiento (ranking)

Aprendizaje no supervisado:

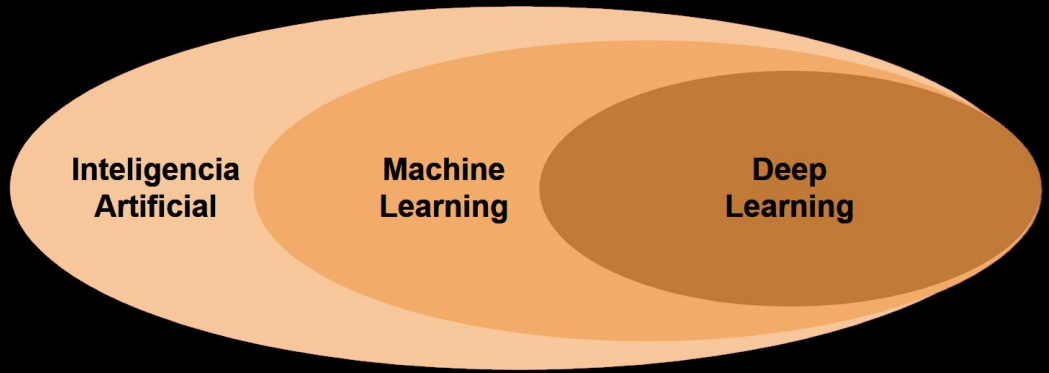
- Los datos no contienen etiquetas explícitas, salvo las características del contexto
- Agrupamiento (clustering), reducción de dimensionalidad, detección de anomalías/valores atípicos (*outliers*)



Aprendizaje profundo

Familia de metodologías supervisadas y no supervisadas que incluyen:

- Arquitecturas de redes neuronales (NN)
- Arquitecturas especializadas, p. ej., CNN...
- Técnicas de regularización
- Enfoques de optimización a gran escala, p. ej., uso de GPU



Redes neuronales artificiales

Dada un a función con un vector de entrada **x** de dimensión *k*, y θ parámetros del modelo, que incluye los pesos sinápticos y sesgos, una **red neuronal artificial** (RNA) es un modelo computacional parametrizado basado en una sucesión de funciones compuestas:

- En la función compuesta, *L* es el número de capas (layers) $l = 1,2,...,L$
- En las funciones de cada capa $f(\mathbf{z},\theta)$, **z** es un vector de entrada que se obtiene de la salida de la capa anterior
- Las funciones de cada capa $f(\mathbf{z},\theta)$ son **expresiones lineales** en una función de activación **no lineal** $\sigma(\cdot)$, con pesos **W** y sesgos **b** para cada capa

$$f(\mathbf{x};\theta) = f_L(f_{L-1}(\dots f_2(f_1(\mathbf{x};\theta_1);\theta_2)\dots);\theta_L)$$

$$f_l(\mathbf{z};\theta_l) = \sigma_l(\mathbf{W}_l\mathbf{z} + \mathbf{b}_l)$$

$$\theta = \{\mathbf{W}_l, \mathbf{b}_l\}_{l=1}^{L}$$

$$\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$\theta^{(t+1)} = \theta^{(t)} - \eta\nabla_\theta\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$w_{ij} \leftarrow w_{ij} - \eta\frac{\partial E}{\partial w_{ij}}$$

Redes neuronales artificiales

Dada un a función con un vector de entrada **x** de dimensión *k*, y θ parámetros del modelo, que incluye los pesos sinápticos y sesgos, una **red neuronal artificial** (RNA) es un modelo computacional parametrizado basado en una sucesión de funciones compuestas:

- La red neuronal se entrena ajustando los parámetros θ para minimizar una función de pérdida que mide las diferencias entre los datos observados y los pronosticados.
- El ajuste de los parámetros se realiza mediante el descenso de gradiente ∇ de la función de pérdida y η es la tasa de aprendizaje

$$f(\mathbf{x};\theta) = f_L(f_{L-1}(\dots f_2(f_1(\mathbf{x};\theta_1);\theta_2)\dots);\theta_L)$$

$$f_l(\mathbf{z};\theta_l) = \sigma_l(\mathbf{W}_l\mathbf{z} + \mathbf{b}_l)$$

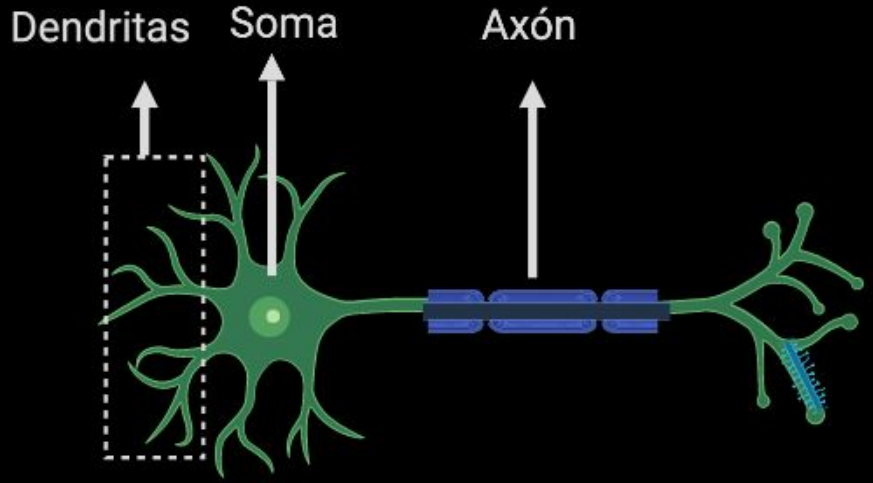
$$\theta = \{\mathbf{W}_l, \mathbf{b}_l\}_{l=1}^{L}$$

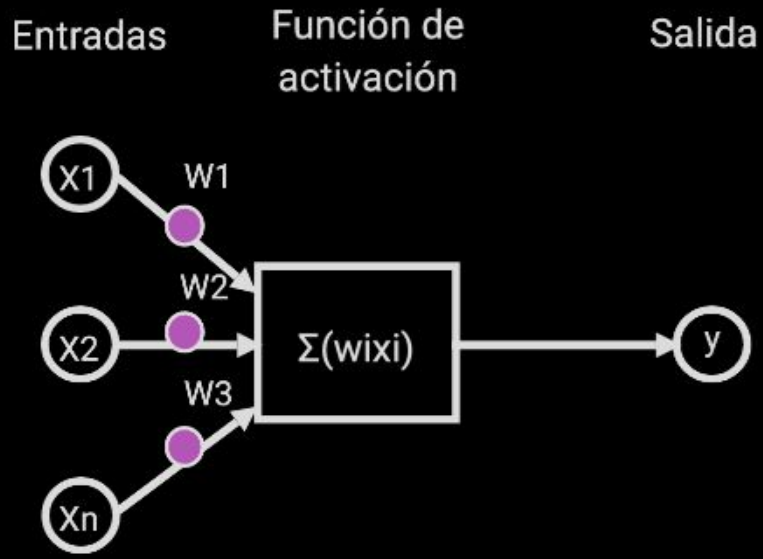
$$\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$\theta^{(t+1)} = \theta^{(t)} - \eta\nabla_\theta\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$w_{ij} \leftarrow w_{ij} - \eta\frac{\partial E}{\partial w_{ij}}$$

Redes neuronales biológicas y redes neuronales artificiales





Redes neuronales artificiales profundas

Dada un a función con un vector de entrada **x** de dimensión *k*, y θ parámetros del modelo, que incluye los pesos sinápticos y sesgos, una **red neuronal artificial** profunda es un modelo computacional parametrizado basado en una sucesión de funciones compuestas igual al de RNA, excepto que

- ***L*** tiene un valor muy grande, específicamente en términos de capas ocultas.
- La optimización se realiza con técnicas de lotes (batch), el uso de funciones activación ReLU, regularización, y variantes modernas de descenso de gradiente estocástico como ADAM

$$f(\mathbf{x};\theta) = f_L(f_{L-1}(\dots f_2(f_1(\mathbf{x};\theta_1);\theta_2)\dots);\theta_L)$$

$$f_l(\mathbf{z};\theta_l) = \sigma_l(\mathbf{W}_l\mathbf{z} + \mathbf{b}_l)$$

$$\theta = \{\mathbf{W}_l, \mathbf{b}_l\}_{l=1}^{L}$$

$$\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$\theta^{(t+1)} = \theta^{(t)} - \eta\nabla_\theta\mathcal{L}(f(\mathbf{x};\theta), \mathbf{y})$$

$$w_{ij} \leftarrow w_{ij} - \eta\frac{\partial E}{\partial w_{ij}}$$

Paralelismos en Econometría/Estadística y ML/DL

Econometría y Estadística	Machine learning/Deep learning
Estimación	Aprendizaje, entrenamiento
Parámetros	Pesos
Variables explicativas (X)	Features/inputs
Variable dependiente (y)	Target/output
Estimación en muestra completa* (muestras limitadas)	Partición de datos (train/test) (big data)
Propósito: inferencia, predicción	Propósito: predicción/clasificación
Maximización del ajuste-en-muestra	Minimización del error de predicción/clasificación

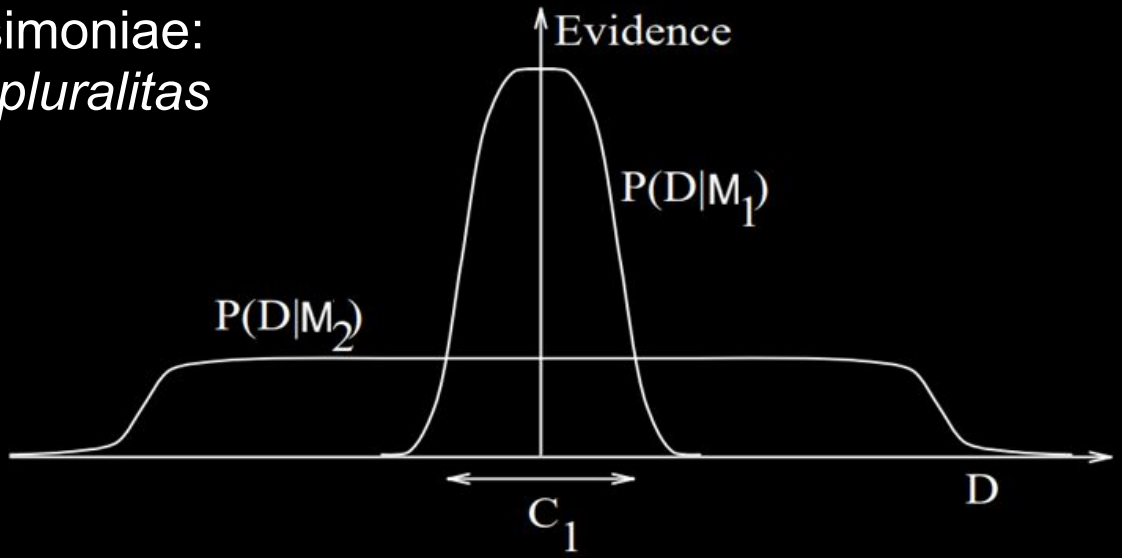
(*) En general, pero no siempre, e.g. rolling estimation

Modelos

- Modelo Matemático: Abstracción para representar, comprender y predecir fenómenos utilizando matemáticas (ecuaciones, funciones, etc.)
  - Los modelos matemáticos son validados mediante la comparación de sus resultados/predicciones contra datos observacionales o experimentales, y pueden ser adaptados y refinados a medida que se dispone de más datos o se comprende mejor el fenómeno estudiado.
  - Epistemológicamente, los modelos son construcciones abstractas que permiten organizar y estructurar el conocimiento de manera sistemática y precisa.

Modelos: un poco de epistemología

- Occam's Razor, lex parsimoniae: *Numquam ponenda est pluralitas sine necessitate*



Modified from: Information Theory, Inference, and Learning Algorithms David J.C. MacKay, Figure 28.3. Why Bayesian inference embodies Occam's razor.

Simple, but not simplistic

It can scarcely be denied that the supreme goal of all theory is to make the irreducible basic elements as simple and as few as possible without having to surrender the adequate representation of a single datum of experience.

A. Einstein, "On the Method of Theoretical Physics," the Herbert Spencer Lecture, Oxford, June 10, 1933.

Algoritmos y modelos

Modelo: Representación simplificada de un proceso, sistema o fenómeno del mundo real. Es una construcción matemática o estadística.

$$\text{salario} = f(\text{educación}, \text{edad}, \text{experiencia})$$

$$\text{salario} = f(\text{educación}, \text{edad}, \text{experiencia}; \Theta)$$

$$\Theta = [\theta_{educ}, \theta_{edad}, \theta_{expe}]$$

$$\text{salario} = f(\text{educación}, \text{edad}, \text{experiencia}; \theta_{educ}, \theta_{edad}, \theta_{expe})$$

Asumiendo que $f(\cdot)$ es lineal:

$$\text{salario} = \theta_0 + \theta_{educ}\,\text{educación} + \theta_{edad}\,\text{edad} + \theta_{expe}\,\text{experiencia}$$

Añadiendo un término i.i.d. $\varepsilon \sim \mathcal{N}(\mu, \sigma^2)$:

$$\text{salario} = \theta_0 + \theta_{educ}\,\text{educación} + \theta_{edad}\,\text{edad} + \theta_{expe}\,\text{experiencia} + \varepsilon$$

Algoritmos y modelos

Algoritmo: Serie de pasos o instrucciones lógicas que se utilizan para realizar una tarea específica.

```
Output: salario
Input: edad, experiencia, educación
if edad > 6
      for (edad) t = 1:n
            educación(t)  = f(estudios)
             while (educación & edad) > aceptable
              for (años) e = 1:m
              experiencia = e
              end
                    salario(t) =  f(educación, edad, experiencia;Θ)
               end
      end
end
```

Algoritmos y modelos

En el contexto de machine learning y deep learning:

- **Modelo: r**epresentación matemática/estadística que se ajusta a los datos y que se utiliza para hacer predicciones o tomar decisiones.
- **Algoritmo:** instrucciones que guían cómo se ajustan los parámetros de un modelo ML durante el proceso de entrenamiento.
- En el proceso de ML, primero se selecciona un algoritmo apropiado para el tipo de problema que se está abordando (supervisado, no supervisado, etc.). Luego, este algoritmo se utiliza para entrenar un modelo específico, ajustando sus parámetros para que el modelo pueda generalizar la tarea a datos nuevos sin sobreajuste.

Algoritmos y modelos

$$\text{salario}_i = \theta_0 + \theta_{educ}\,\text{educación}_i + \theta_{edad}\,\text{edad}_i + \theta_{expe}\,\text{experiencia}_i + \varepsilon_i$$

Algoritmo de estimación:

Input: **datos de salarios, educación, edad, experiencia**

Output: **estimadores de** $\theta_{educ}, \theta_{edad}, \theta_{expe}$

1. Representación matricial:

$$\boldsymbol{\Theta} = [\theta_{educ}, \theta_{edad}, \theta_{expe}]$$
$$\mathbf{X} = [\text{educación}_i, \text{edad}_i, \text{experiencia}_i]$$
$$\mathbf{y} = [\text{salario}_1, \text{salario}_2, \ldots, \text{salario}_n]$$
$$\mathbf{y} = \mathbf{X}\,\boldsymbol{\Theta} + \boldsymbol{\varepsilon}$$
$$\mathbf{y} - \mathbf{X}\,\boldsymbol{\Theta} = \boldsymbol{\varepsilon}$$

2. Operaciones matriciales: cálculo de matrices transpuestas e inversas, $\mathbf{X}'$, $(\mathbf{X}'\mathbf{X})^{-1}$

3. Estimadores MCO:

$$\underset{\substack{\boldsymbol{\Theta}\in\mathbb{R} \\ i=1,2,\ldots,n}}{\text{argmin}}\ \boldsymbol{\varepsilon}: \ \widehat{\boldsymbol{\Theta}} = (\mathbf{X}'\mathbf{X})^{-1}\,\mathbf{X}'\mathbf{y}$$

4. Estimadores MCO: $\hat{\theta}_{educ}, \hat{\theta}_{edad}, \hat{\theta}_{expe}$

Variables

Las variables se dividen en varias categorías según su naturaleza y el tipo de valores que pueden tomar.

1.Variables Cualitativas (o Categóricas):

- Nominales: Son variables que representan categorías sin un orden inherente. Ejemplos incluyen el color de ojos (azul, verde, marrón) o el tipo de mascota (perro, gato, pájaro).
- Ordinales: Son variables que representan categorías con un orden lógico, pero sin una distancia uniforme entre categorías. Ejemplos incluyen los niveles de satisfacción (insatisfecho, neutral, satisfecho) o las clasificaciones (primero, segundo, tercero).

2. Variables Cuantitativas (o Numéricas):

- Discretas: Son variables que toman valores contables, generalmente números enteros. Ejemplos incluyen el número de hijos en una familia o el número de coches en un garaje.
- Continuas: Son variables que pueden tomar cualquier valor dentro de un rango, incluyendo fracciones y decimales. Ejemplos incluyen la altura, el peso o la temperatura.

Tipos de datos: modelos benchmark

Tipo de dato	Ejemplos	Modelos frecuentes
Nominal	Sexo, país	Regresión logística
Ordinal	Nivel educativo, satisfacción (1–5), nivel socioeconómico	Regresión logística ordinal
Discreto	Número de hijos, accidentes, llamadas	Regresión de Poisson
Continuo	Ingreso, peso, temperatura, PIB	Regresión lineal

Tipos de datos: modelos RNA shallow y profundos

Tipo de dato	Ejemplos	Modelos frecuentes de aprendizaje profundo
Nominal	Default crediticio	Redes de clasificación binaria (Sigmoid) y multiclase (Softmax)
Ordinal	Categoria de riesgo, satisfacción (1–5), nivel socioeconómico	Redes neuronales ordinales (e.g. CORAL)
Discreto	Número de siniestros	Poisson neural networks
Continuo	Ingreso, peso, temperatura, PIB	MLP, redes recurrentes

Las arquitecturas de redes neuronales no se determinan exclusivamente por el tipo de variable dependiente, pero a naturaleza de la variable dependiente (target) determina principalmente la capa de salida, su función de activación y la función de pérdida.

Tipos de estructuras de datos

Tipo de datos	Descripción	Ejemplo	Modelos comunes
Cross-sectional (corte transversal)	Unidades observadas en un único momento del tiempo.	Encuesta de 5000 hogares en 2026.	OLS, Logit, Probit
Series de tiempo (Time Series)	Una misma unidad observada repetidamente a lo largo del tiempo.	Inflación mensual (2000–2026).	ARIMA, ARDL, VAR, VECM, GARCH
Panel o Longitudinal	Varias unidades observadas durante varios períodos.	PIB de 150 países entre 1990 y 2025.	Panel con efectos fijos, efectos aleatorios, panel dinámico, GMM
Datos espaciales	Observaciones ubicadas geográficamente con posible dependencia espacial.	Precios de viviendas por municipio.	SAR, SEM
Datos espacio-temporales	Combinan dimensión espacial y temporal.	Incidencia mensual de dengue por distrito.	Modelos espacio-temporales, Bayesian hierarchical models
Datos jerárquicos o multinivel	Observaciones agrupadas en distintos niveles.	Estudiantes dentro de escuelas.	Modelos multinivel o de efectos mixtos
Datos de supervivencia	Tiempo hasta que ocurre un evento.	Tiempo hasta recaída de un paciente.	Cox, Weibull, Kaplan–Meier

Tipos de estructuras de datos: modelos RNA shallow y profundos

Tipo de datos	Modelos frecuentes de redes neuronales y Deep Learning (ejemplos)
Cross-sectional (corte transversal)	MLP, DNN, TabNet
Series de tiempo (Time Series)	RNN, LSTM, GRU, Transformers temporales
Panel o Longitudinal	Deep Mixed-Effects Models
Datos espaciales	CNN, Graph Neural Networks (GNN)
Datos espacio-temporales	ConvLSTM, Spatio-Temporal GNN (ST-GNN), Spatio-Temporal Transformers
Datos jerárquicos o multinivel	Bayesian Neural Networks
Datos de supervivencia	DeepSurv, DeepHit, Cox-nnet, Deep Survival Machines

Variables

3. Variables Dependientes e Independientes:

- Independientes: Son variables que se manipulan o controlan para observar su efecto sobre otras variables. En un experimento, son las que el investigador cambia para ver cómo afectan a la variable dependiente.
- Dependientes: Son variables que se miden para ver el efecto de las variables independientes. En un experimento, son las que se observan y registran para ver cómo cambian en respuesta a las variables independientes.

4. Variables Dicotómicas: variables que sólo pueden tomar dos valores posibles.

5. Variables de Escala:

- Intervalo: Son variables cuantitativas donde la distancia entre dos valores tiene significado, pero no hay un verdadero cero. Ejemplo: temperatura en grados Celsius.
- Razón: Son variables cuantitativas donde hay un verdadero cero y se pueden realizar operaciones matemáticas significativas. Ejemplo: peso, altura, ingresos.

Estandarización de los datos

La estandarización no garantiza un mejor desempeño predictivo no es obligatoria para entrenar una RNA pero pero suele ser recomendable porque:

$$z_t = \frac{P_t - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

1. Facilita la optimización: los gradientes suelen comportarse mejor cuando las variables están en escalas apropiadas.
2. Mejora la estabilidad numérica: evita introducir valores excesivamente grandes en las operaciones de las redes.
3. Reduce problemas de saturación: especialmente importantes en RNN, LSTM y GRU, que utilizan funciones como `tanh` y `sigmoid`.
4. Puede acelerar la convergencia: el optimizador Adam puede alcanzar una solución adecuada con menos épocas.

Momentos

La esperanza de una variable aleatoria es una medida de su tendencia central, que resume el valor esperado de esta variable.
Esperanza de una variable aleatoria (definición). *La esperanza de una variable aleatoria $g(X)$, denotada por $\mathbb{E}(X)$,es*

$$\mathbb{E}(X) \begin{cases} \sum_{x \in X} g(X) f(X) = \sum_{x \in X} g(X) \mathbb{P}(X = x) \text{ si } X \text{ es discreta} \\ \int_{-\infty}^{\infty} g(X) f(X) dx \text{ si } X \text{ es continua,} \end{cases}$$

Sea una muestra $x_1, ..., x_n$. La esperanza $\mathbb{E}(X)$ está relacionada con el primer momento muestral (la media),

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Segundo momento y momentos superiores

El segundo momento central es la varianza.

Varianza (definición). *La varianza de una variable aleatoria X es su segundo momento central, $Var(X) = \mathbb{E}(X - \mathbb{E}(X))^2$. La raíz cuadrada positiva de $Var(X)$ es la desviación estándar de X.*

La varianza proporciona una medida del grado de dispersión de una distribución alrededor de la media. La varianza muestral de una muestra $x_1, ..., x_n$ se calcula con,

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^{n} \left(X_i - \overline{X}_n\right)^2$$

Momentos superiores son el sesgo y la curtosis de una distribución. El sesgo mide el grado de simetría de una distribución, y la curtosis el grado de apuntamiento de la distribución. Dependiendo del valor de la curtosis, una distribución puede ser leptocúrtica (curtosis $>$ 3), mesocúrtica (curtosis $=$ 3) o platicúrtica (curtosis $<$ 3).

Particiones muestrales en ML y DL

- **Partición en muestra train y test:** Método más básico y común. Se divide los datos en dos partes: un conjunto de entrenamiento para entrenar el modelo (estimar los parámetros del modelo) y un conjunto de prueba para evaluar el rendimiento del modelo en datos no vistos.
- **Hold-Out con Validación:** similar a la partición en entrenamiento y prueba, pero incluye un tercer conjunto de validación:
  - **Entrenamiento (Train):** Para ajustar los parámetros del modelo.
  - **Validación (Validation):** Para ajustar hiperparámetros y evitar sobreajuste.
  - **Prueba (Test):** Para la evaluación final del modelo.

Particiones muestrales en machine learning

Partición de datos en 4 grupos:

Entrenamiento (train): $i = 1,\ldots,m$

persona	salario	educación	edad	experiencia
$i = 1$	2640	24	40	10
⋮	⋮	⋮	⋮	⋮
$i = 8$	6400	30	57	12
⋮	⋮	⋮	⋮	⋮
$i = m$	3555	29	32	9

y train | X entrenamiento (train)

El conjunto de entrenamiento se utiliza para entrenar el modelo (estimar los parámetros del modelo)

Evaluación (test): $i = m, m+1,\ldots, n$

persona	salario	educación	edad	experiencia
$i = m$	5656	27	38	5
$i = m+1$	3322	24	37	10
⋮	⋮	⋮	⋮	⋮
$i = n$	4300	32	40	13

y test | X test

El conjunto de prueba se emplea para evaluar el rendimiento del modelo en datos no vistos

Particiones muestrales

Partición de datos:

Entrenamiento (train): $i = 1,\ldots,m$

$$\text{salario}_i = \theta_0 + \theta_{educ}\text{educación}_i + \theta_{edad}\text{edad}_i + \theta_{expe}\text{experiencia}_i + \varepsilon_i$$

$$\boldsymbol{\Theta} = [\theta_{educ}, \theta_{edad}, \theta_{expe}],$$

$$\mathbf{X_train} = [\text{educación}_i, \text{edad}_i, \text{experiencia}_i]$$

$$\mathbf{y_train} = [\text{salario}_1, \text{salario}_2, \ldots, \text{salario}_m]$$

$$\mathbf{y_train} = \mathbf{X}\,\boldsymbol{\Theta} + \boldsymbol{\varepsilon}$$

$$\underset{\substack{\boldsymbol{\Theta}\in\mathbb{R} \\ i=1,2,\ldots,m}}{\text{argmin}}\ \boldsymbol{\varepsilon}: \widehat{\boldsymbol{\Theta}} = (\mathbf{X_train}'\mathbf{X_train})^{-1}\mathbf{X_train}'\mathbf{y_train}$$

Evaluación (test): $i = m, m+1,\ldots, n$

$$\boldsymbol{y}_{pronostico} = \mathbf{X}_{\mathbf{test}}\widehat{\boldsymbol{\Theta}}$$

Error cuadrático medio (MSE):

$$MSE = \frac{1}{m}\sum_{i=m}^{n}(y_{test,i} - y_{pronostico,i})^2$$

El conjunto de entrenamiento se utiliza para entrenar el modelo (estimar los parámetros del modelo)

El conjunto de prueba se emplea para evaluar el rendimiento del modelo en datos no vistos

Particiones muestrales: La validación cruzada k-fold (k-fold cross-validation)

- En muestras pequeñas, k = n (particion LOO)
- Valores convencionales: k = 5, k = 10, k =20. Depende del tamaño de los datos y el costo computacional

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$$

$$\mathcal{D}_1, \mathcal{D}_2, \ldots, \mathcal{D}_k$$

$\mathcal{D}_i \subset \mathcal{D}$ para todo i y $\mathcal{D}_i \cap \mathcal{D}_j = \emptyset$ para $i \neq j$.

Para cada $i = 1, 2, \ldots, k$:

$$\mathcal{D}_{-i} = \mathcal{D} \setminus \mathcal{D}_i = \bigcup_{j \neq i} \mathcal{D}_j.$$

$h(\cdot; \theta_i)$ usando $\mathcal{D}_{-i}$

$$E_i = \frac{1}{|\mathcal{D}_i|} \sum_{(x_j, y_j) \in \mathcal{D}_i} \ell(h(x_j; \theta_i), y_j)$$

$$E_{\mathrm{CV}} = \frac{1}{k} \sum_{i=1}^{k} E_i$$

Particiones muestrales:
Experimento de pseudo-pronóstico fuera de muestra

$$\{y_t, \mathbf{x}_t\}_{t=1}^{T}$$

$$\underbrace{1, \ldots, T_0}_{\text{Estimación}} \implies \hat{y}_{T_0+1|T_0}$$

$$\underbrace{2, \ldots, T_0+1}_{\text{Estimación}} \implies \hat{y}_{T_0+2|T_0+1}$$

$$\vdots$$

$$\underbrace{T-H, \ldots, T-1}_{\text{Estimación}} \implies \hat{y}_{T|T-1}$$

$$\hat{\boldsymbol{\beta}}_t = \arg\min_{\boldsymbol{\beta}} \sum_{i=t-T_0+1}^{t} \left(y_i - \mathbf{x}_i'\boldsymbol{\beta}\right)^2$$

$$\hat{y}_{t+1|t} = \mathbf{x}_{t+1}'\hat{\boldsymbol{\beta}}_t, \qquad t = T_0, \ldots, T-1$$

$$e_{t+1} = y_{t+1} - \hat{y}_{t+1|t}$$

$$RMSE = \sqrt{\frac{1}{H}\sum_{t=T_0}^{T-1} e_{t+1}^2}$$

$$MAE = \frac{1}{H}\sum_{t=T_0}^{T-1} |e_{t+1}|$$

Evaluación de modelos de aprendizaje profundo

- Durante el entrenamiento: funciones de perdida (loss)
- Durante la validacion: metricas para evaluar cada modelo y comparar entre modelos

Problema	Métricas principales
Clasificación	Accuracy, Precision, Recall, F1
Clasificación desbalanceada	F1, PR-AUC, Recall, Precision
Clasificación probabilística	ROC-AUC, PR-AUC
Regresión	MAE, MSE, RMSE, R2
Forecasting	MAE, RMSE, MAPE
Segmentación (computer vision)	IoU, Dice
Object detection	IoU, AP, mAP
NLP	Perplexity, BLEU, ROUGE
Modelos generativos	FID, IS

Métricas para datos continuos

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Matriz de confusión

En problemas de clasificación, métricas basadas en la **matriz de confusión** pueden utilizarse para comparar y seleccionar modelos de machine learning:

	Predicción Positiva	Predicción Negativa
Clase Positiva	Verdadero Positivo (TP)	Falso Negativo (FN)
Clase Negativa	Falso Positivo (FP)	Verdadero Negativo (TN)

Métricas basadas en la Matriz de confusión

- La exactitud se define como la proporción de predicciones correctas (tanto positivas como negativas) sobre el total de predicciones realizadas.

$$\text{Exactitud (Accuracy)} = \frac{\text{Número de predicciones correctas}}{\text{Número total de predicciones}}$$

$$\text{Exactitud (Accuracy)} = \frac{TP+TN}{TP+TN+FP+FN}$$

En caso de datos desbalanceados otras medidas como el score F1 y la sensibilidad (recall) son más apropiadas

Métricas basadas en la Matriz de confusión

- **Precisión (Positive Predictive Value):** Proporción de ejemplos correctamente clasificados como positivos entre todos los clasificados como positivos.
- **Sensibilidad (Recall, True Positive Rate, TPR):** Proporción de ejemplos positivos correctamente identificados entre todos los ejemplos que son realmente positivos.
- **Especificidad (Specificity o True Negative Rate, TNR):** Proporción de ejemplos negativos correctamente identificados entre todos los ejemplos que son realmente negativos.

$$\text{Precisión} = \frac{TP}{TP + FP}$$

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

Métricas basadas en la Matriz de confusión

- **Valor Predictivo Negativo:** Proporción de negativos entre todos los ejemplos que fueron clasificados como negativos.
- **F1-Score:** Media armónica entre la precisión y la sensibilidad
- **Tasa de Falsos Positivos:** Proporción de ejemplos negativos que fueron incorrectamente clasificados como positivos.

$$\text{Valor Predictivo Negativo} = \frac{TN}{TN + FN}$$

$$\text{F1-Score} = \frac{2 \times \text{Precisión} \times \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

$$\text{Tasa de Falsos Positivos} = \frac{FP}{FP + TN}$$

Métricas basadas en la Matriz de confusión

Exactitud balanceada, prevalencia (porcentaje de casos positivos), prevalencia de detección (casos predichos como positivos), tasa de detección (casos correctamente predichos como positivos):

$$\text{Exactitud Balanceada} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2}$$

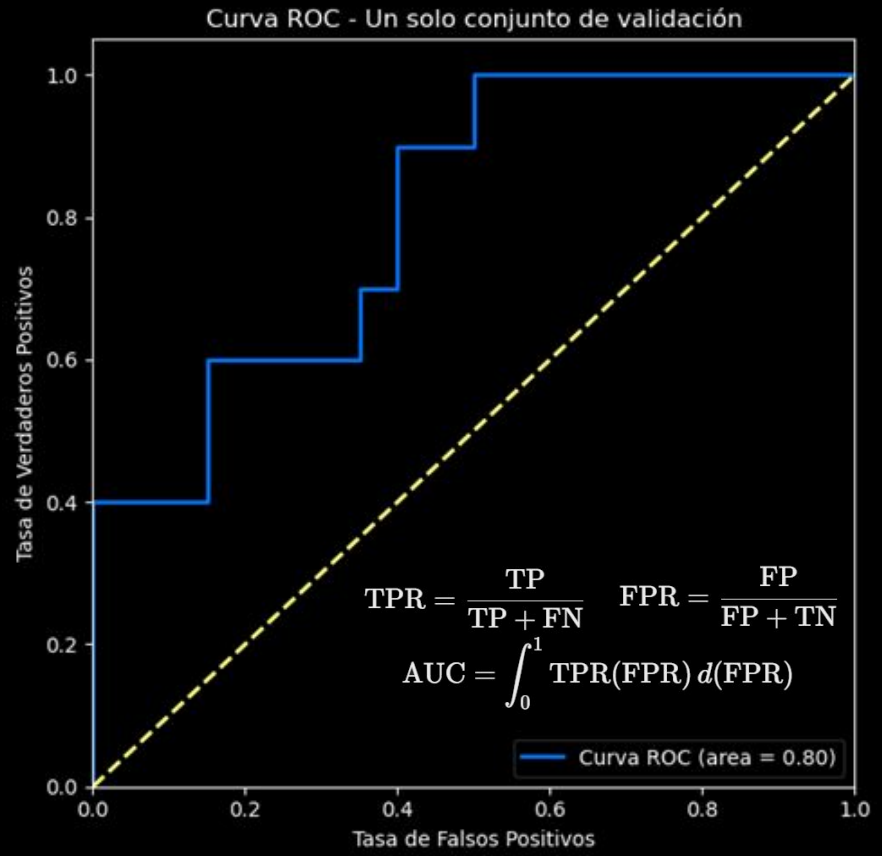
$$\text{Prevalencia} = \frac{TP + FN}{TP + TN + FP + FN}$$

$$\text{Prevalencia de Detección} = \frac{TP + FP}{TP + TN + FP + FN}$$

$$\text{Tasa de Detección} = \frac{TP}{TP + TN + FP + FN}$$

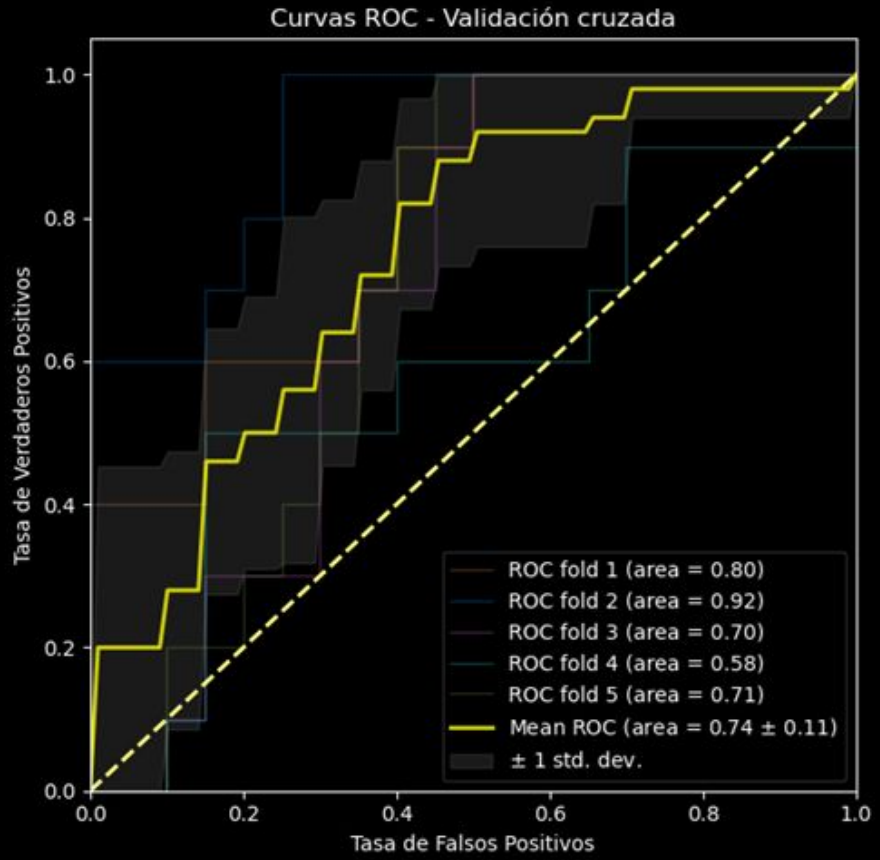
Curva ROC (Receiver Operating Characteristic) y validación de modelos ML

- ROC: representación gráfica de la capacidad de un modelo de clasificación para discriminar entre clases.
- Muestra la relación entre la Tasa de Verdaderos Positivos (TPR) y la Tasa de Falsos Positivos (FPR) para diferentes umbrales de corte de la probabilidad predicha:
    - Eje X (tasa de falsos positivos, FPR): Proporción de negativos que son incorrectamente clasificados como positivos.
    - Eje Y (tasa de verdaderos positivos, TPR o Sensibilidad): Proporción de positivos correctamente identificados por el modelo.



Curva ROC (Receiver Operating Characteristic) y validación de modelos ML

- El rendimiento de un modelo ML depende de la partición del conjunto de datos utilizado para el entrenamiento.
- Técnicas de validación cruzada y hypertuning permiten evaluar y controlar la estabilidad y generalización del modelo para dar una estimación robusta de la capacidad discriminatoria/predictiva de los modelos ML



Otras métricas basadas en la matriz de confusión: Kappa de Cohen

- Kappa de Cohen es una métrica que se utiliza para evaluar la concordancia entre dos clasificadores.
- Es una medida estadística que compara la precisión observada (Po) de un modelo con la precisión esperada (Pe) si las predicciones fueran completamente aleatorias

$$\text{Kappa} = \frac{P_o - P_e}{1 - P_e} \qquad P_o = \frac{TP + TN}{\text{Total de casos}}$$

Probabilidad marginal para la clase positiva:

$$P_{\text{real, positiva}} = \frac{TP + FN}{\text{Total}} \qquad P_{\text{predicha, positiva}} = \frac{TP + FP}{\text{Total}}$$

Probabilidad marginal para la clase negativa:

$$P_{\text{real, negativa}} = \frac{TN + FP}{\text{Total}} \qquad P_{\text{predicha, negativa}} = \frac{TN + FN}{\text{Total}}$$

$$P_e = (P_{\text{real, positiva}} \times P_{\text{predicha, positiva}}) + (P_{\text{real, negativa}} \times P_{\text{predicha, negativa}})$$

Otras métricas basadas en la matriz de confusión: Kappa de Cohen

Interpretación:

- **Kappa = 1**: Indica un acuerdo perfecto entre el modelo y las etiquetas verdaderas.
- **Kappa = 0**: Indica que el acuerdo es igual al que se esperaría por azar (es decir, no hay un acuerdo más allá de lo que el azar proporciona).
- **Kappa < 0**: Indica un acuerdo peor que el azar, lo que sugiere que el modelo está haciendo un trabajo pobre en clasificar correctamente.
- **Kappa entre 0.6 y 0.8**: Se considera un acuerdo sustancial.
- **Kappa entre 0.8 y 1**: Se considera un acuerdo casi perfecto.

Otras métricas basadas en la matriz de confusión: Test de McNemar

- Se puede utilizar para comparar (1) las predicciones de un clasificador contra los datos reales, o (2) las predicciones de dos clasificadores.

	Observado Positivo (1)	Observado Negativo (0)
Predicción Positiva (1)	n_{11}	n_{10}
Predicción Negativa (0)	n_{01}	n_{00}

$$M = \frac{(n_{10} - n_{01})^2}{n_{10} + n_{01}} \sim \chi^2(df = 1)$$

Otras métricas basadas en la matriz de confusión: Test de McNemar

- Se puede utilizar para comparar (1) las predicciones de un clasificador contra los datos reales, o (2) las predicciones de dos clasificadores.
- La hipótesis nula es que no hay diferencia entre las proporciones de discordancia (i.e. los elementos fuera de la diagonal son iguales), por lo que no rechazar la hipótesis nula:
  - En el caso de (1) sugiere un buen ajuste del modelo.
  - En el caso de (2) indica que no hay diferencias entre clasificadores. El rechazo de la nula implica que uno de los clasificadores es mejor que el otro clasificador.

Otras métricas

IoU (Intersection over Union), Dice, Fréchet Inception Distance, perplexity

$$IoU = \frac{|Prediction \cap GroundTruth|}{|Prediction \cup GroundTruth|}$$

$$Dice = \frac{2|Prediction \cap GroundTruth|}{|Prediction| + |GroundTruth|}$$

$$PP = \exp\left(-\frac{1}{N}\sum_{i=1}^{N}\log P(w_i)\right)$$

Estimación y aprendizaje

La estimación es el proceso de extraer información acerca del valor de cierto parámetro poblacional a partir de la muestra $x_1, ..., x_n$, utilizando algún estadígrafo como estimador, calculado con los datos $x_1, ..., x_n$.

Estadígrafo.

Considérese que se obtiene una muestra de tamaño n de una población. Un estadígrafo es una función que se obtiene utilizando como datos las observaciones de la muestra $x_1, ..., x_n$.

Estimación puntual e interválica

Dado un modelo de regresión:

$$y = \beta_0 + \beta_1 x + \epsilon$$

Los estimadores puntuales son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Estimación puntual e interválica

Un intervalo de confianza (1 - α)% es:

$$\beta_1 \pm t_{n-2,\,\alpha/2} \times SE(\beta_1)$$

Donde:

$$SE(\beta_1) = \sqrt{\frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}}$$

$$\sigma^2 = \frac{\sum_{i=1}^{n} e_i^2}{n-2} \qquad e_i = y_i - \hat{y}_i \qquad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Definición matemática de aprendizaje: logro de objetivos en términos de estimación de parámetros y predicción

1. Dado un modelo paramétrico: $\hat{y} = f(x;\theta)$
2. Un conjunto de entrenamiento: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n},$
3. El aprendizaje es:

$$\hat{\theta} = \arg\min_{\theta} \frac{1}{n} \sum_{i=1}^{n} L\left(y_i, f(x_i;\theta)\right)$$

Una vez que los parámetros han sido "aprendidos", para una observación nueva x^*: $\hat{y}^* = f(x^*;\hat{\theta})$

(i.e. la predicción resulta de aplicar lo aprendido a información no observada durante el entrenamiento)

$$\mathcal{D} \longrightarrow \hat{\theta} \longrightarrow f(x^*;\hat{\theta}) \longrightarrow \hat{y}^*$$

Definición matemática de aprendizaje profundo

1. **Dado un modelo profundo con L capas:**

$$\hat{y} = f(x;\Theta) = f^{(L)}\Big(f^{(L-1)}\big(\cdots f^{(1)}\big(x;\theta^{(1)}\big)\cdots;\theta^{(L-1)}\big);\theta^{(L)}\Big)$$

2. **Representaciones intermedias:**

$$\begin{aligned} h^{(1)} &= \phi^{(1)}\big(W^{(1)}x + b^{(1)}\big) \\ h^{(\ell)} &= \phi^{(\ell)}\big(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)}\big), \quad \ell = 2,\ldots,L \\ \hat{y} &= g(h^{(L)}) \end{aligned}$$

3. **Dado un conjunto de entrenamiento:**

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}$$

4. **El aprendizaje profundo consiste en estimar todos los parámetros:**

$$\hat{\Theta} = \arg\min_{\Theta} \frac{1}{n}\sum_{i=1}^{n} \mathcal{L}\big(y_i, f(x_i;\Theta)\big)$$

A diferencia del aprendizaje paramétrico general, el aprendizaje profundo no solo ajusta parámetros para predecir, sino que aprende representaciones jerárquicas de los datos a través de múltiples niveles de abstracción.

Para una nueva observación x^*: $h^{(1)*} \rightarrow h^{(2)*} \rightarrow \cdots \rightarrow h^{(L)*} \rightarrow \hat{y}^* = f(x^*;\hat{\Theta})$

Definición matemática de aprendizaje profundo

Un modelo profundo es un modelo con múltiples niveles de representación

la salida resulta de **muchas transformaciones sucesivas:**

$$x \to h^{(1)} \to h^{(2)} \to \cdots \to h^{(L)} \to \hat{y}$$

- Existen modelos no estrictamente neuronales que también pueden considerarse “profundos” porque tienen estructura jerárquica o composicional, por ejemplo **Deep Gaussian Processes**

- En la práctica, el aprendizaje profundo se basa principalmente en redes neuronales artificiales multicapa

Regresión lineal múltiple y estimación

Forma no matricial

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta \square x \square_i + u_i$$

Para cada observación i = 1, …, n:

- y_i es la variable dependiente observada.
- $x\square_i$ es la j-ésima variable explicativa.
- $\beta\square$ es el parámetro asociado a $x\square_i$.
- u_i resume factores omitidos y error aleatorio.

Interpretación ceteris paribus:

$\beta\square$ mide el cambio esperado en y cuando $x\square$ aumenta una unidad, manteniendo constantes las demás variables explicativas.

Idea central: la regresión múltiple estima asociaciones parciales

Estimadores MCO (OLS)

Dado un modelo de regresión multivariante expresado en notación matricial:

$$\underset{(n\times 1)}{\mathbf{y}} = \underbrace{\underset{(n\times k)}{\mathbf{X}}\ \underset{(k\times 1)}{\beta}}_{(n\times 1)} + \underset{(n\times 1)}{\varepsilon}$$

$$\underset{(n\times 1)}{\mathbf{y}} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \underset{(n\times 1)}{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}, \quad \underset{(n\times k)}{\mathbf{X}} = \begin{bmatrix} x_{11} & \cdots & x_{1k} \\ x_{21} & \cdots & x_{2k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nk} \end{bmatrix},$$

Estimadores MCO (OLS)

Se busca obtener estimadores que minimicen la suma de residuos al cuadrado

$$\underset{(n\times 1)}{\mathbf{y}} = \underbrace{\underset{(n\times k)}{\mathbf{X}}\ \underset{(k\times 1)}{\beta}}_{(n\times 1)} + \underset{(n\times 1)}{\varepsilon}$$

$$\underset{(k\times 1)}{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

$$\widehat{\beta} \equiv \underset{\widehat{\beta}}{\arg\min} SSR(\widehat{\beta})$$

$$SSR(\widehat{\beta}) = (\mathbf{y} - \mathbf{X}\widehat{\beta})'(\mathbf{y} - \mathbf{X}\widehat{\beta})$$

Estimadores MCO (OLS)

Se busca obtener estimadores que minimicen la suma de residuos al cuadrado

$$\underset{(n\times 1)}{\mathbf{y}} = \underbrace{\underset{(n\times k)}{\mathbf{X}}\ \underset{(k\times 1)}{\beta}}_{(n\times 1)} + \underset{(n\times 1)}{\varepsilon}$$

$$\underset{(k\times 1)}{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

$$\widehat{\beta} \equiv \underset{\widehat{\beta}}{\arg\,\text{mín}} SSR(\widehat{\beta})$$

$$\widehat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Estimación frecuentista con máxima verosimilitud

- La función $\mathcal{L}(\theta|\mathbf{x})$ –denominada función de verosimilitud– es una cantidad matemática que expresa la verosomilitud, plausibilidad, de que el parámetro θ tome un valor concreto en base a la información contenida en la muestra $\mathbf{x} = (x_1, ..., x_n)$
- En la función de verosimilitud $\mathcal{L}(\theta|\mathbf{x})$, la muestra permanece constante, y θ varía en el espacio paramétrico Θ. Situación contraria a $\mathbb{P}(\mathbf{x}|\theta)$, ya que en este caso, θ permanece constante y lo que se compara son los posibles sucesos $\mathbf{x}_1, \mathbf{x}_2, ...$ para el mismo valor de θ.

Estimación frecuentista con máxima verosimilitud

Sea una variable aleatoria ξ con una función de densidad $f(x;\theta)$. Si se toma una muestra de tamaño n, $x_1, ..., x_n$, la función de densidad conjunta de la muestra será,

$$f(x_1, ..., x_n; \theta) = f(x_1; \theta) \cdots f(x_n; \theta)$$

esta función de densidad conjunta será la función de verosimilitud muestral,

$$\mathcal{L}(\theta|\mathbf{x}) := f(x_1; \theta) \cdots f(x_n; \theta)$$

La elección del estimador $\widehat{\theta}$ entre los posibles valores que puede tomar el parámetro θ se sgue el criterio de elegir aquel $\widehat{\theta}$ tal que,

$$\mathcal{L}(\widehat{\theta}|\mathbf{x}) = \underset{\theta \in \Theta}{\text{máx}} \mathcal{L}(\theta|\mathbf{x})$$

Estimación frecuentista con máxima verosimilitud

Ya que en general la función de verosimilitud es complicada, para mayor sencillez se calcula el valor de θ en su logaritmo,

$$\ln \mathcal{L}(\widehat{\theta}|\mathbf{x}) = \max_{\theta \in \Theta} \ln \mathcal{L}(\theta|\mathbf{x})$$

$$\ln \mathcal{L}(\theta|\mathbf{x}) = \ln f(x_1;\theta) + \cdots + \ln f(x_n;\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta)$$

Una vez hallado el logaritmo se deriva respecto a θ,

$$\frac{\partial \ln \mathcal{L}(\theta|\mathbf{x})}{\partial \theta} = \sum_{i=1}^{n} \frac{\partial \ln f(x_i;\theta)}{\partial \theta} = 0$$

Ejemplo: Estimación frecuentista con máxima verosimilitud del primer momento

Sean una muestra i.i.d. $x := \{x_t\}_{t=1}^{m} = x_1, ..., x_m$, si $x \sim \mathcal{N}(\mu, \sigma^2)$, la función de verosimilitud $\mathcal{L}\left(\mu, \sigma^2\right)$ será,

$$
\begin{aligned}
\mathcal{L}\left(\mu, \sigma^2\right) &= f(x_1, ..., x_m | \mu, \sigma^2) \\
&= \prod_{i=1}^{m} f(x_i | \mu, \sigma^2) \\
&= \left(\frac{1}{2\pi\sigma^2}\right)^{n/2} \exp\left(-\frac{\sum_{i=1}^{m}\left(x_i - \mu\right)^2}{2\sigma^2}\right)
\end{aligned}
$$

Ejemplo: Estimación frecuentista con máxima verosimilitud del primer momento estadístico

$\mathcal{L}\left(\mu, \sigma^2\right)$ puede escribirse en función de $\overline{x}$,

$$\mathcal{L}\left(\mu, \sigma^2\right) = \left(\frac{1}{2\pi\sigma^2}\right)^{n/2} \exp\left(-\frac{\sum_{i=1}^{m}\left(x_i - \overline{x}\right)^2 + m\left(\overline{x} - \mu\right)^2}{2\sigma^2}\right).$$

Si se aplica logaritmos a $\mathcal{L}\left(\mu, \sigma^2\right)$ y se maximiza derivando respecto al parámetro de interés μ e igualando a cero:

$$\frac{\partial}{\partial\mu} \log\left(\frac{1}{2\pi\sigma^2}\right)^{n/2} \exp\left(-\frac{\sum_{i=1}^{m}\left(x_i - \overline{x}\right)^2 + m\left(\overline{x} - \mu\right)^2}{2\sigma^2}\right) = 0$$

se tendrá el estimador máximo verosimil,

$$\widehat{\mu} = \overline{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$$

Estimación frecuentista máximo verosímil del MLRM

Dado un modelo lineal de regresión múltiple (MLRM) en el que:

$$\underset{(n\times 1)}{\mathbf{y}} = \underbrace{\underset{(n\times k)}{\mathbf{X}}\ \underset{(k\times 1)}{\beta}}_{(n\times 1)} + \underset{(n\times 1)}{\varepsilon}$$

$$\varepsilon|\mathbf{X} \sim \mathcal{N}(0, \sigma^2\mathbf{I}_n)$$

$$\mathbf{y}|\mathbf{X} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2\mathbf{I}_n)$$

La función de verosimilitud es:

$$\mathcal{L}\left(\beta, \sigma^2 \middle| \mathbf{X}, \mathbf{y}\right) = \left(2\pi\sigma^2\right)^{-\frac{n}{2}} \left[-\frac{1}{2\sigma^2}\left(\mathbf{y}-\mathbf{X}\beta\right)'\left(\mathbf{y}-\mathbf{X}\beta\right)\right]$$

Y los estimadores que maximizan la función son:

$$\widehat{\beta}_{MV} = \left(\mathbf{X}'\mathbf{X}\right)^{-1}\mathbf{X}'\mathbf{y}$$

Estimación con descenso gradiente (gradient descent)

El descenso de gradiente es un algoritmo de optimización iterativo que busca minimizar una función de pérdida, modificando los parámetros del modelo en la dirección opuesta al gradiente (gradiente es el vector de derivadas parciales de la función de pérdida respecto a los parámetros).

$$\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial L}{\partial \theta_1} \\ \frac{\partial L}{\partial \theta_2} \\ \vdots \\ \frac{\partial L}{\partial \theta_p} \end{pmatrix}$$

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$$

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}^{(t)})$$

$$\theta_j^{(t+1)} = \theta_j^{(t)} - \eta \frac{\partial L}{\partial \theta_j}$$

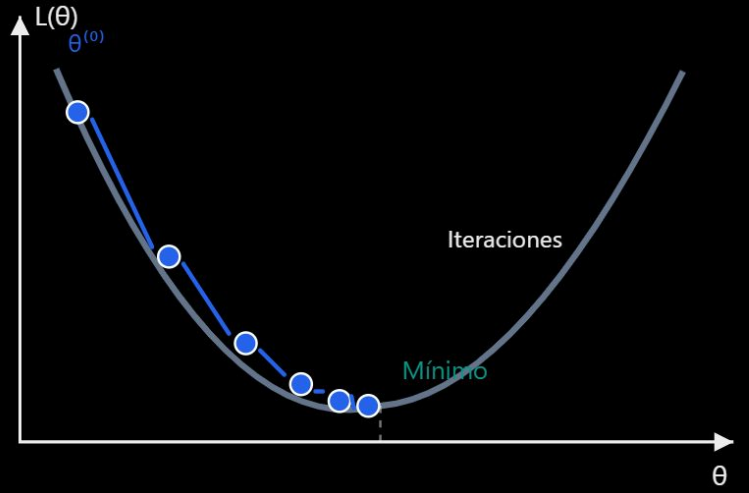
t: iteración del algoritmo.

$\eta > 0$: tasa de aprendizaje (*learning rate*).

$\nabla_{\boldsymbol{\theta}} L$: gradiente de la pérdida.

Estimación con descenso gradiente (gradient descent)

- En una red neuronal, con matrices de pesos W y vectores de sesgos b para cada l-capa, las derivadas se calculan mediante retropropagación del error (backpropagation)
- Variantes: Batch Gradient Descent, Stochastic Gradient Descent (SGD), Mini-batch Gradient Descent



$$W^{(l,t+1)} = W^{(l,t)} - \eta \frac{\partial L}{\partial W^{(l)}}$$

$$b^{(l,t+1)} = b^{(l,t)} - \eta \frac{\partial L}{\partial b^{(l)}}$$

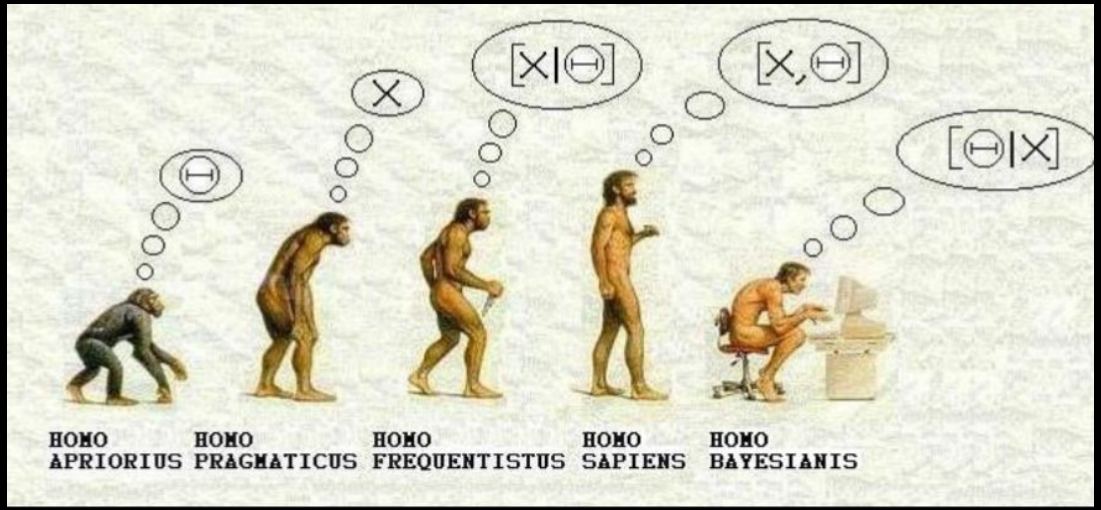
Enfoque Bayesiano

A philosophical theory, like a physics or a mathematical theory, is accessible only to the initiated.

Simone the Beauvoir

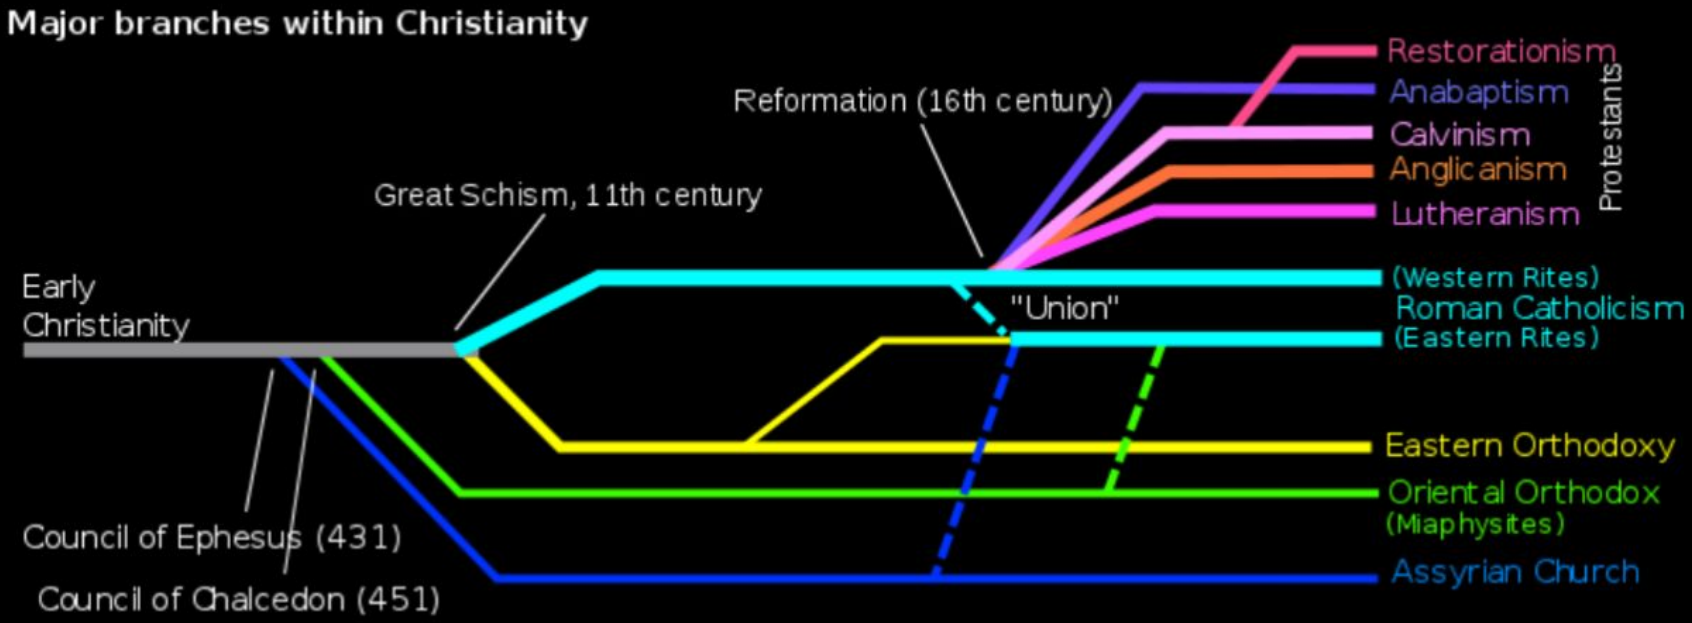
Estimación Bayesiana

- La estimación Bayesiana no es simplemente un “método adicional o diferente” de estimación:
- El enfoque Bayesiano es un paradigma estadístico diferente.
- Epistemológicamente, un paradigma científico diferente.



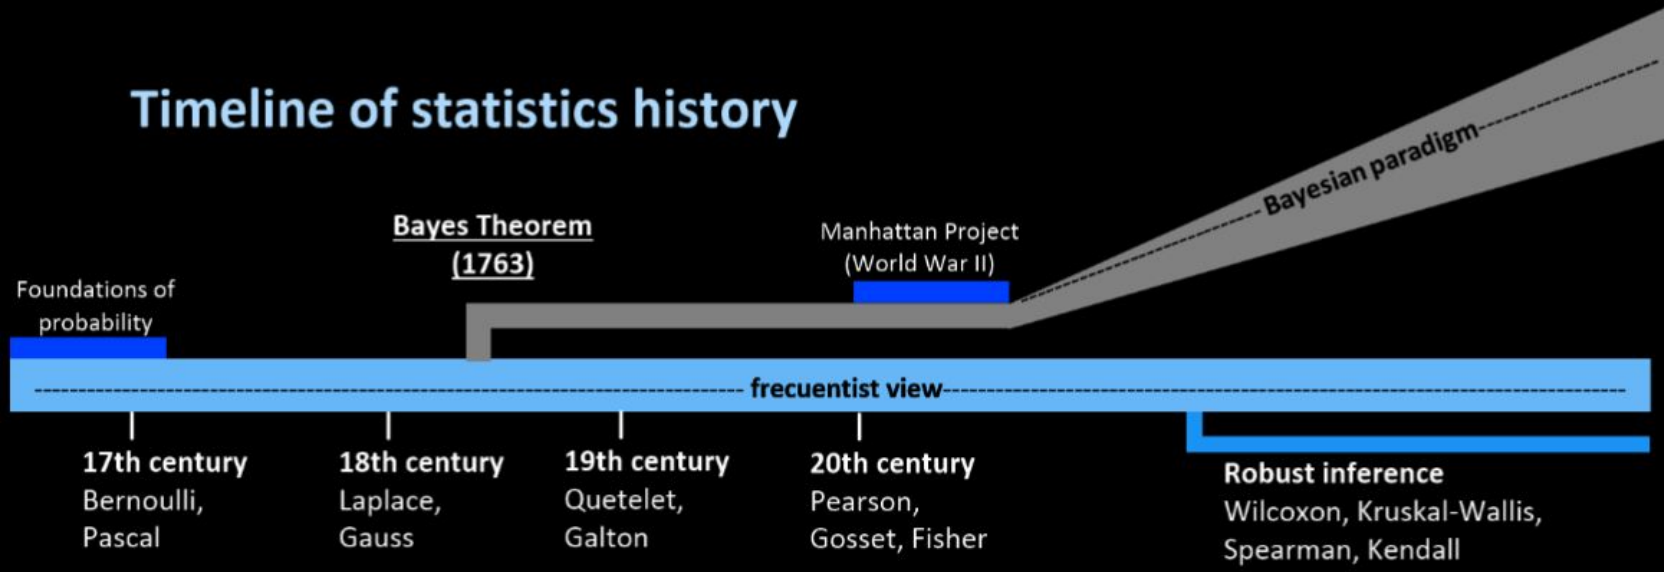
Enfoque Bayesiano

Analogía con el cristianismo



Enfoque Bayesiano

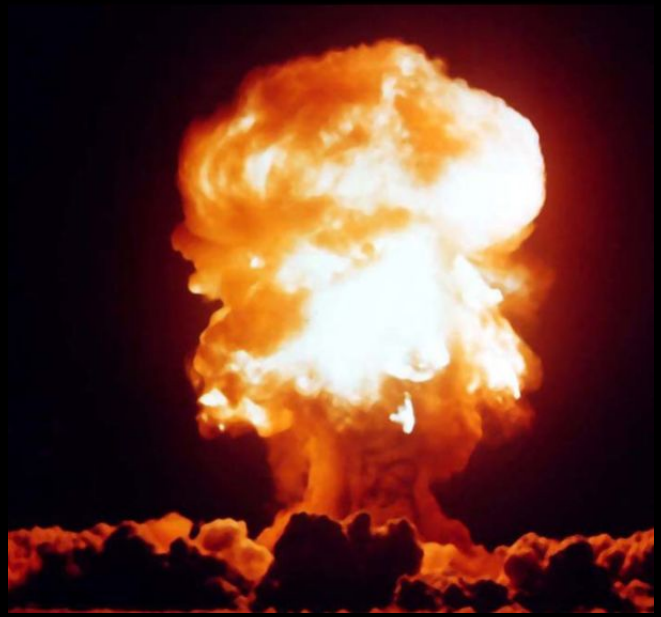
Antes de la segunda guerra mundial se utilizaban conjugados naturales



Enfoque Bayesiano

Antes de la segunda guerra mundial se utilizaban conjugados naturales

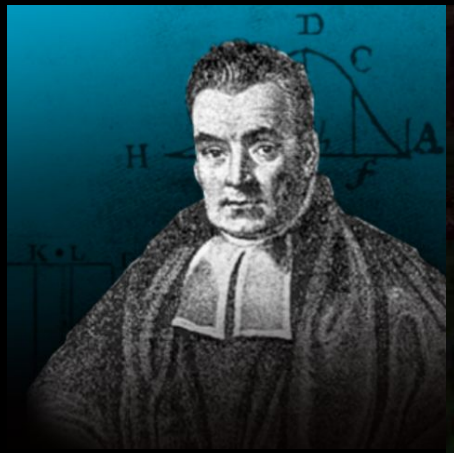
- Métodos de Monte Carlo —desarrollados durante el El Proyecto Manhattan— permitieron aproximar la integrales multidimensionales del análisis Bayesiano.
- El crecimiento exponencial del software y hardware computacional han hecho el uso de los métodos de integración de Monte Carlo más accesible.



Enfoque Bayesiano

- El término bayesiano se refiere a Thomas Bayes (1702 - 1761), quien propuso una solución al problema de probabilidad inversa utilizando lo que hoy se conoce como Teorema de Bayes.
- La solución de Bayes fue publicada póstumamente por Richard Price en Transacciones filosóficas vol. 53 (1763), págs. 370-418
- El mecanismo de Bayes fue descubierto de forma independiente, refinado y publicado en 1774 por Pierre Simon de Laplace

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A)\mathbb{P}(B|A)}{\mathbb{P}(B)}$$





Enfoque Bayesiano

La regla de Bayes surge de los axiomas de probabilidad y no es una materia de controversia.

La división trata sobre la interpretación filosófica de probabilidad P(A):

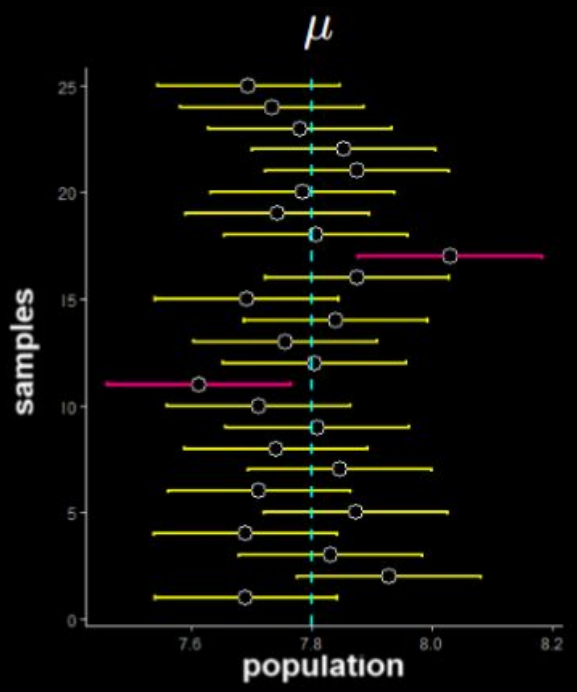
- Para un frecuentista, P(A) es una frecuencia de largo plazo:

$$\mathbb{P}(A) := \lim_{n \to \infty_+} \frac{n_A}{n}$$

- Para un Bayesiano, P(A) es cualquier conocimiento/información sobre el evento A, además del contenido en los datos, incluyendo la incertidumbre sobre A.

Enfoque frecuentista:

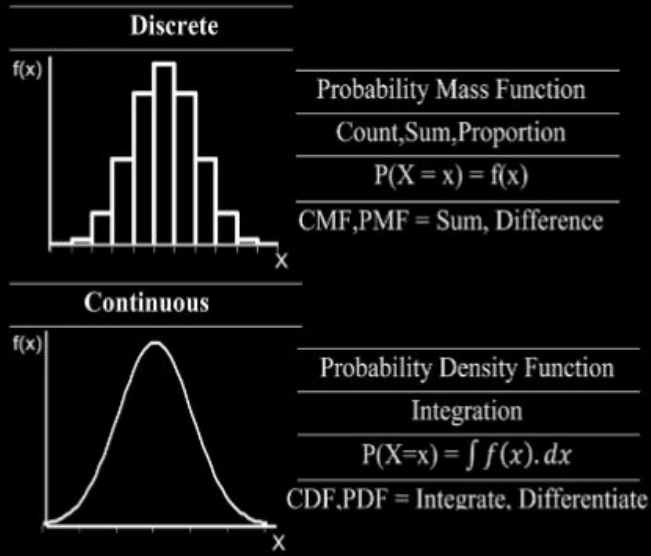
- Los datos son aleatorios
- Los parámetros son (puntos) fijos



Enfoque Bayesiano:

- Los datos son fijos
- Los parámetros son aleatorios

$$\mu \sim \mathcal{D}(\theta_1, \theta_2, ...\theta_d), \text{ e.g.}$$
$$\mu \sim \mathcal{N}(\theta_\mu, \sigma_\mu^2),\ \theta_\mu \sim \mathcal{E}(\lambda_{\theta_\mu})$$



Estimación Bayesiana del MLRM

Con priors no informativos los estimadores Bayesianos coinciden con los estimadores máximo verosímiles:

$$\mathbb{P}(\beta) \propto c \text{ y } \mathbb{P}(\sigma^2) \propto \sigma^{-1}$$

$$\mathbb{P}(\beta, \sigma^2) \propto \mathcal{L}\left(\beta, \sigma^2 \middle| \mathbf{X}, \mathbf{y}\right)\mathbb{P}(\beta)\mathbb{P}(\sigma^2)$$

$$\propto \sigma^{-n-1} \exp\left[-\frac{1}{2\sigma^2}(\hat{\sigma}^2(n-k) + (\beta - \hat{\beta})'\mathbf{X}'\mathbf{X}(\beta - \hat{\beta}))\right]$$

Estimación Bayesiana del MLRM

Con priors informativos:

$$\beta \sim \mathcal{N}_k(\beta_0, B_0), \quad \sigma^2 \sim \mathcal{IG}(\alpha_0/2, \delta_0/2),$$

$$\beta|\sigma^2, y \sim \mathcal{N}(\overline{\beta}, B_1), \qquad \sigma^2|\beta, y \sim \mathcal{IG}(\alpha_1/2, \delta_1/2)$$

$$B_1 = [s^{-2}X'X + B_0^{-1}]^{-1},$$

$$\overline{\beta} = B_1[\sigma^{-2}X'y + B_0^{-1}\beta_0],$$

$$\alpha_1 = \alpha_0 + n,$$

$$\delta_1 = \delta_0 + (y - X\beta)'(y - X\beta)$$

Estimación Bayesiana

- Basada en el teorema de Bayes
- Estimación con conjugados naturales
- Estimación con MCMC (Markov Chain Monte Carlo: Monte Carlo con Cadenas de Markov)
- Estimación MCMCMC (MC3)

Software y Hardware

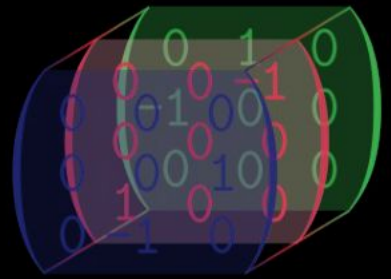
Software

Computación en la nube y local

- R
  - R Studio IDE*
  - R analytic flow IDE
  - Posit cloud (R Studio)
  - Stata
- Python
  - Spyder IDE (Anaconda)
  - Anaconda cloud (Jupyter)
  - Google Colab (Jupyter)
- Matlab

Hardware

- CPU
- GPU
- TPU



(*) IDE: integrated development environment

R

https://www.r-project.org/



Lenguaje y entorno para computación desarrollado por Robert Gentleman y Ross Ihaka (Universidad de Auckland) end 1993.

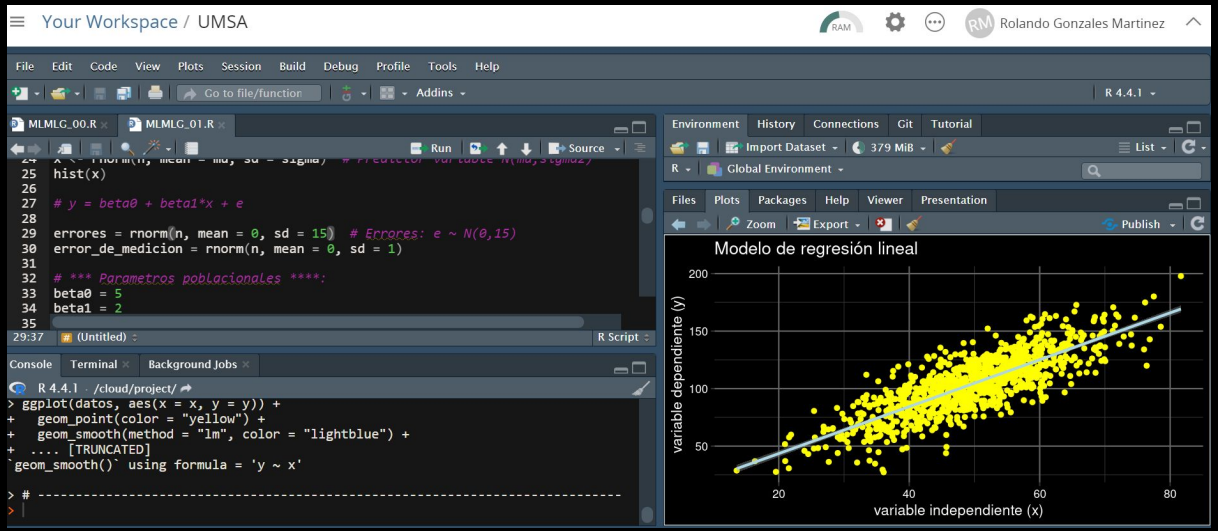
- Similar al lenguaje y entorno S que fue desarrollado en Bell Laboratories (anteriormente AT&T, ahora Lucent Technologies) por John Chambers y colegas a finales de los 70’s.

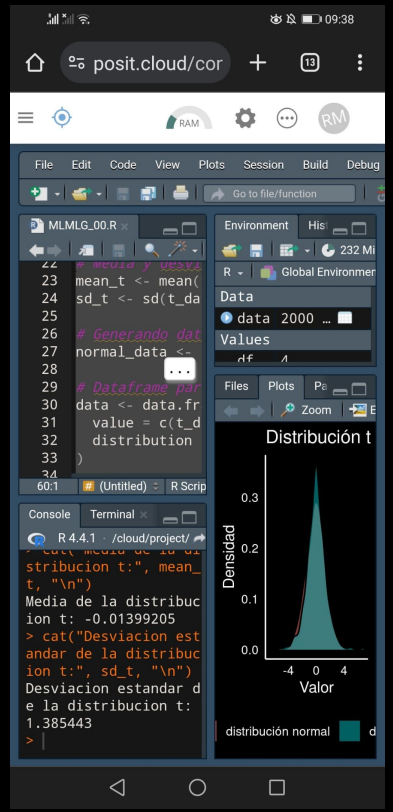
- R está disponible como Software Libre bajo los términos de la Licencia Pública General GNU de la Free Software Foundation en forma de código fuente.

- Compila y se ejecuta en una amplia variedad de plataformas UNIX y sistemas similares (Linux), Windows y MacOS.

Posit cloud: R en la nube

Permite correr R en la nube,
incluso desde un teléfono celular





Python

- Lenguaje de programación.
- Python fue concebido a fines de la década de 1980 por Guido van Rossum en Centrum Wiskunde & Informatica (CWI) en los Países Bajos.
- 2000: Python 2.0
- 2018: Guido van Rossum, el "dictador benévolo de por vida" de Python, responsable de la toma de decisiones del proyecto, deja el proyecto
- 2022: Python 3.x

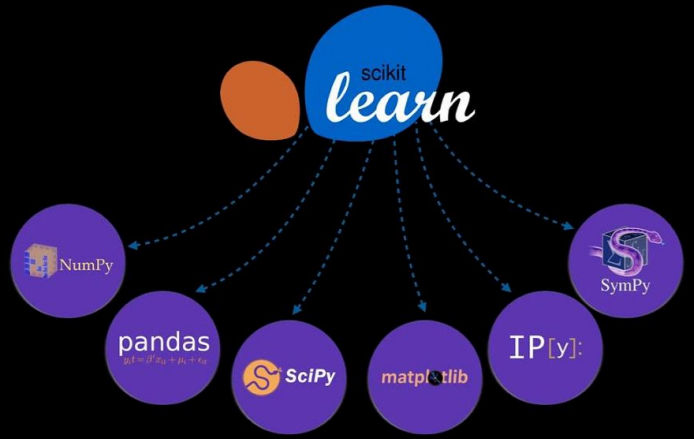


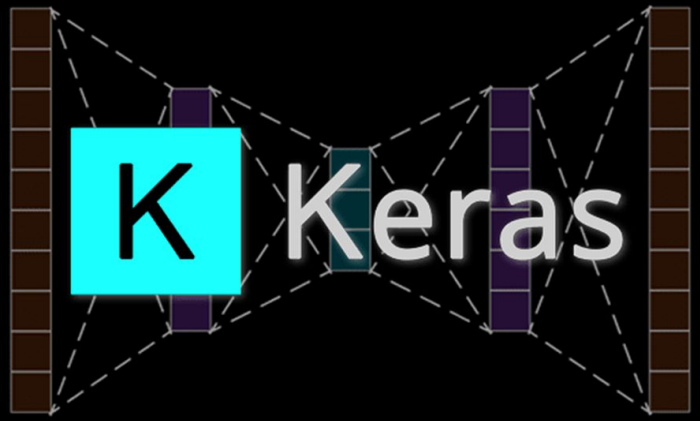
Wikipedia, Google, Yahoo!, CERN, NASA, Facebook, Amazon, Instagram, Spotify

Python: librerias

Librerias/paquetes especializados:

- Numpy
- Pandas
- Matplotlib
- Scikit-learn
- Tensorflow
- Keras

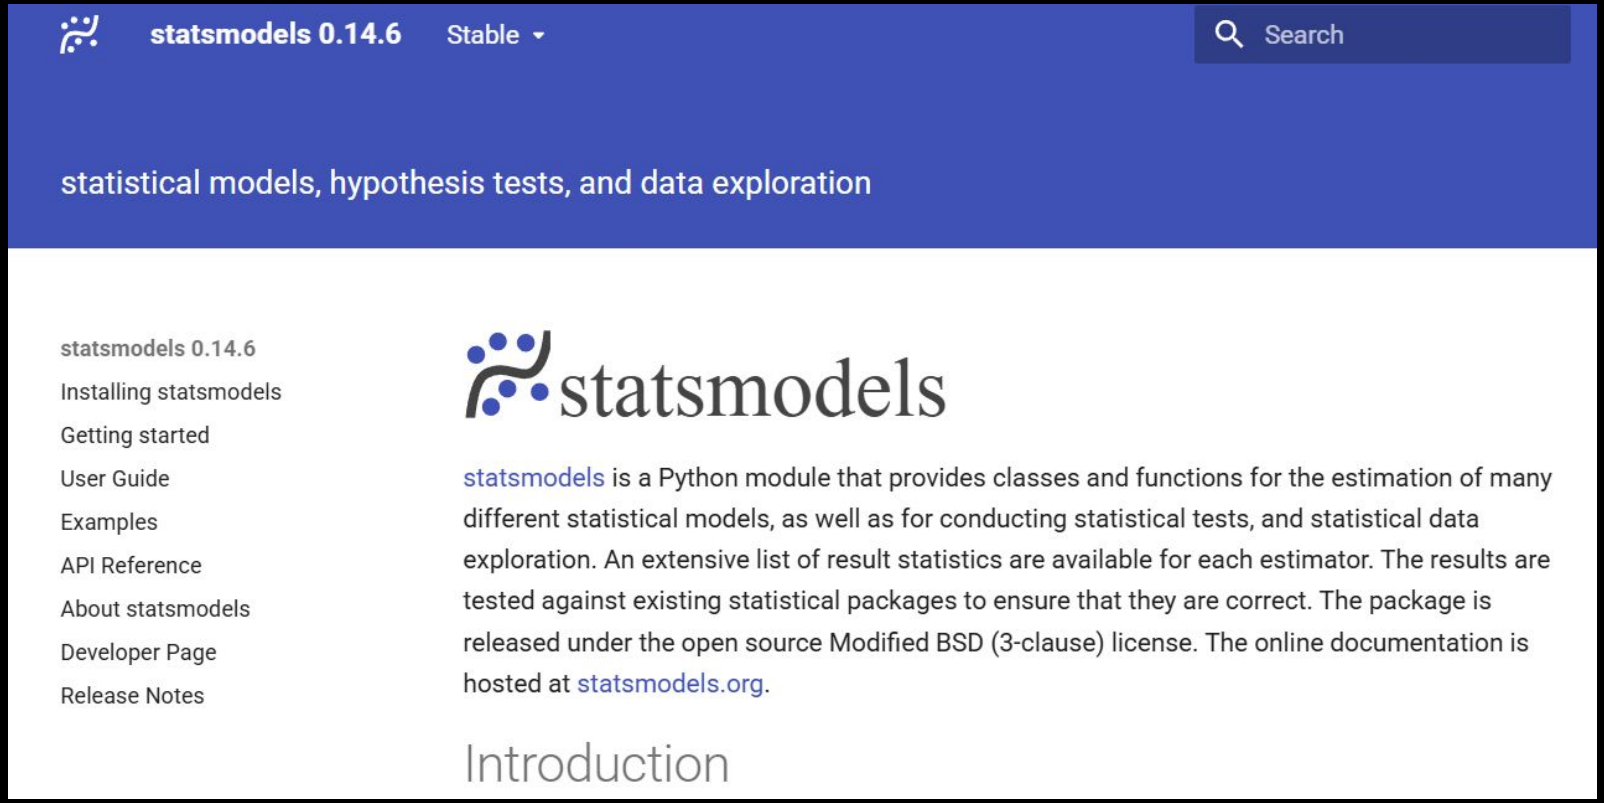




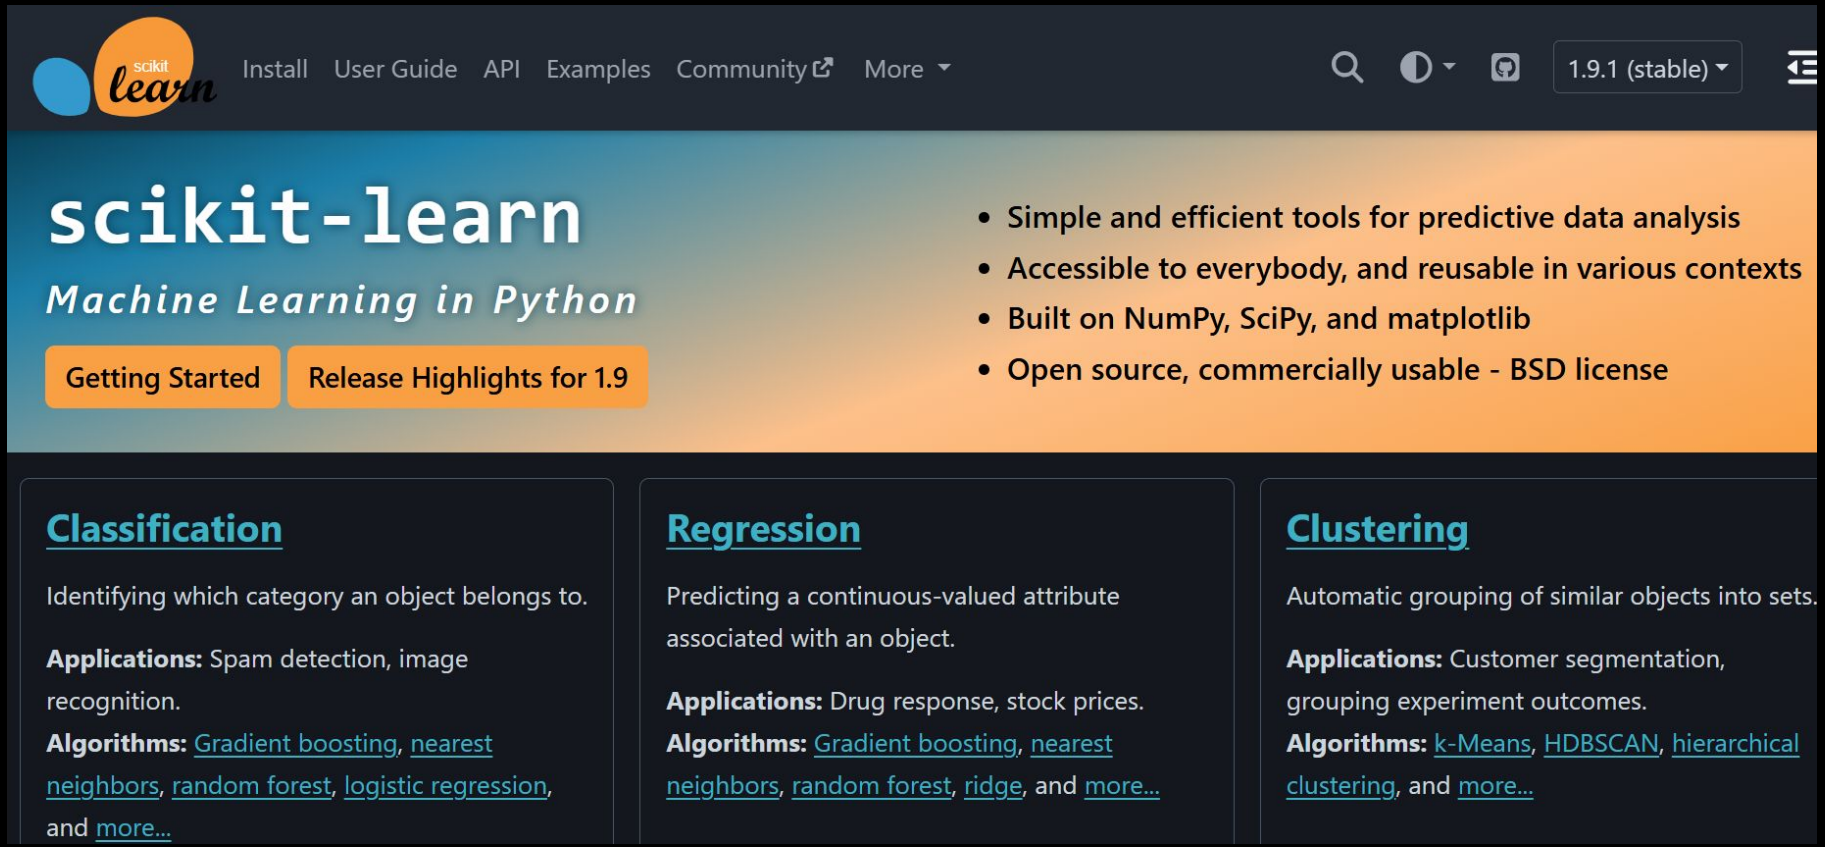




Python library: statsmodels



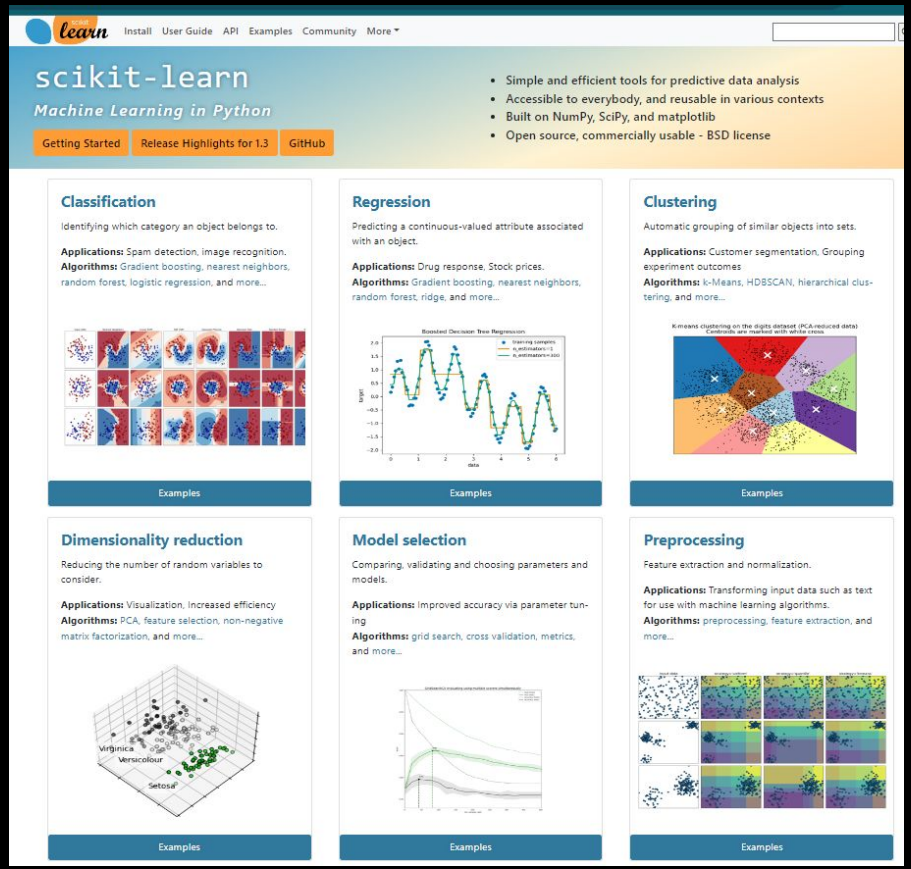
Python library for ML: sci-kit learn



Python: Scikit-learn

https://scikit-learn.org/stable/

- Clasificación
- Regresión
- Agrupamiento (clustering)
- Reducción de la dimensionalidad
- Selección de modelos
- Pre-procesamiento de datos (preparación de datos)



Librerias Python para aprendizaje profundo:

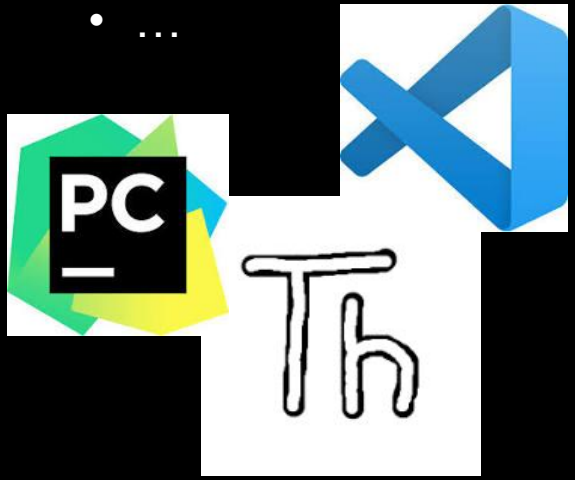


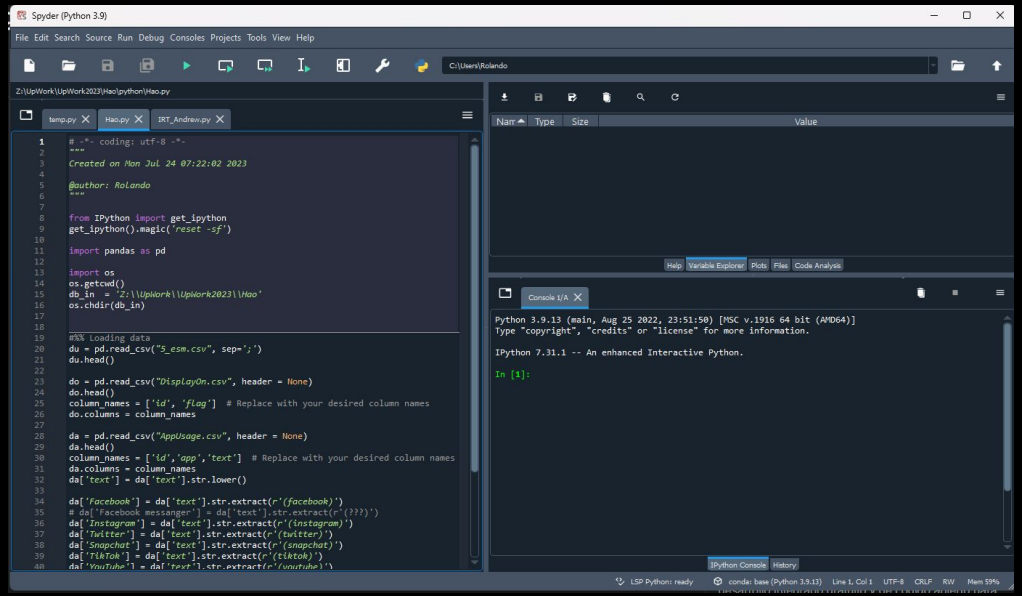


Python

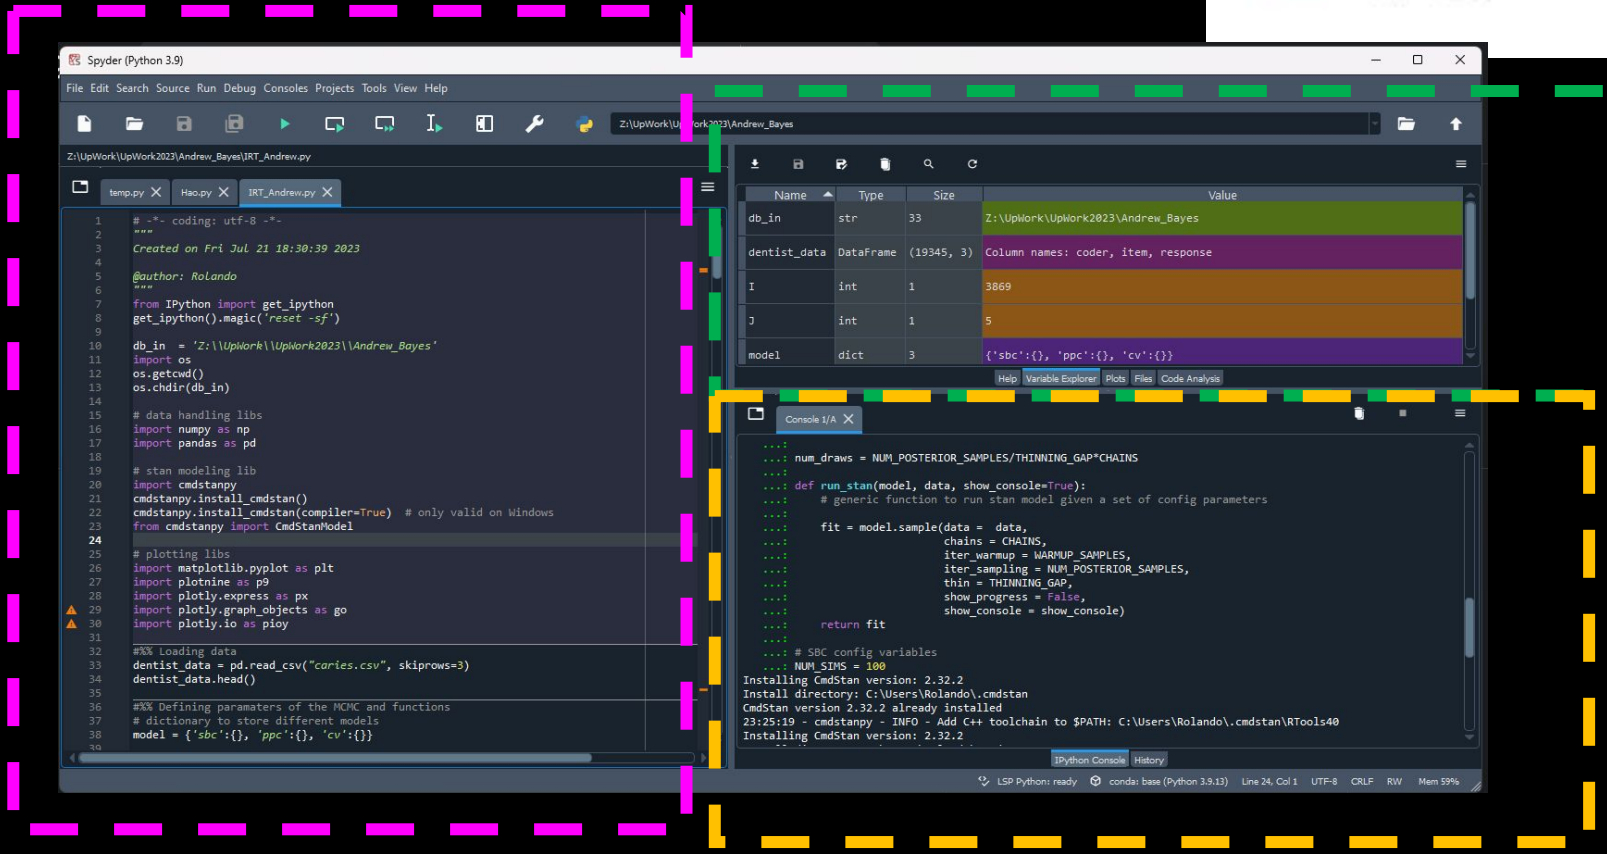
IDE (Integrated Development Environments):

- PyCharm
- Jupyter
- Spyder
- Python IDLE
- Thonny
- …



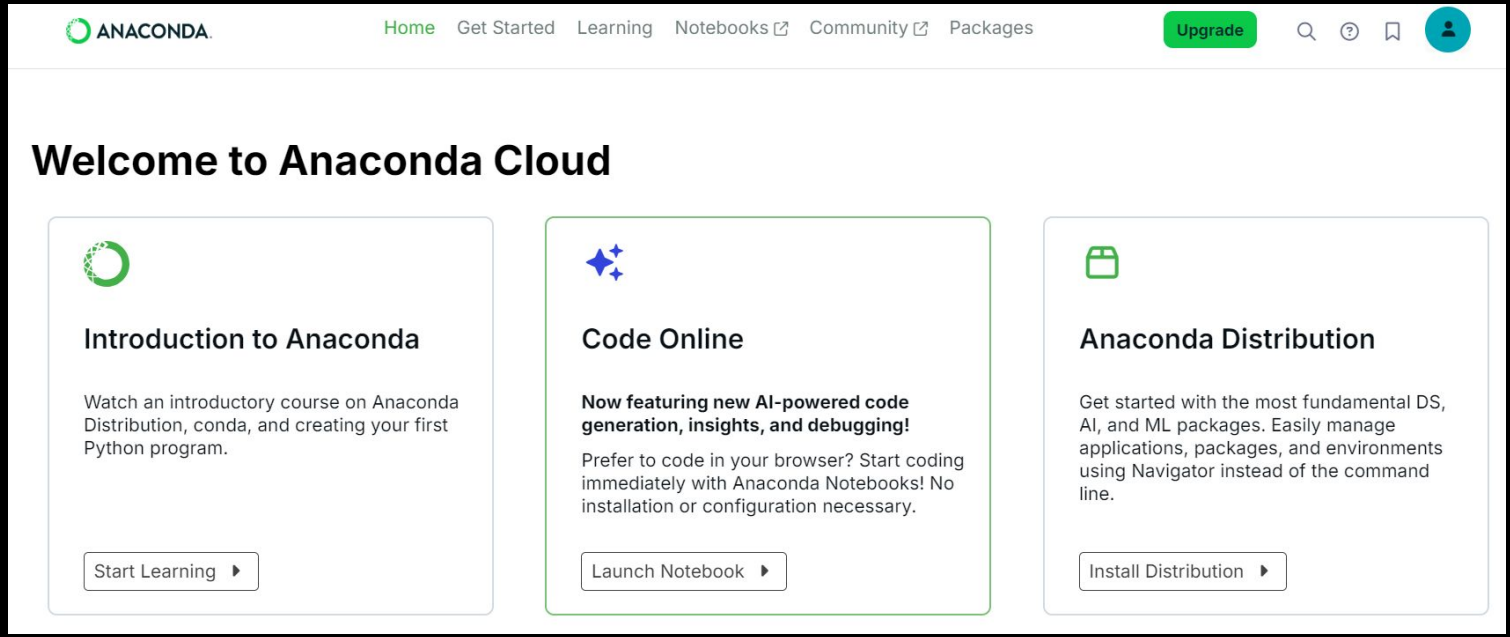


Python y Spyder

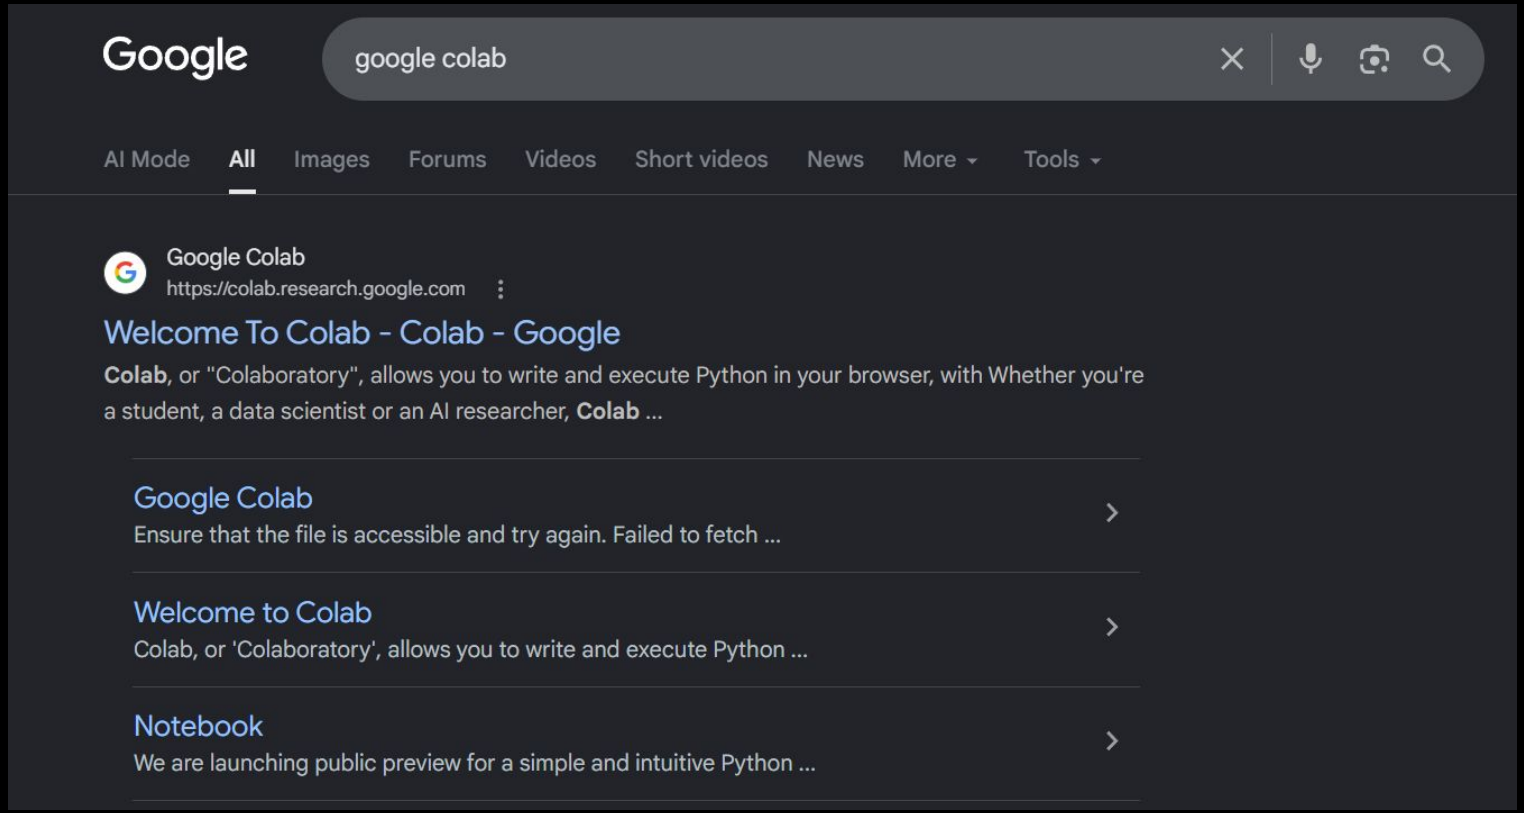


Anaconda cloud

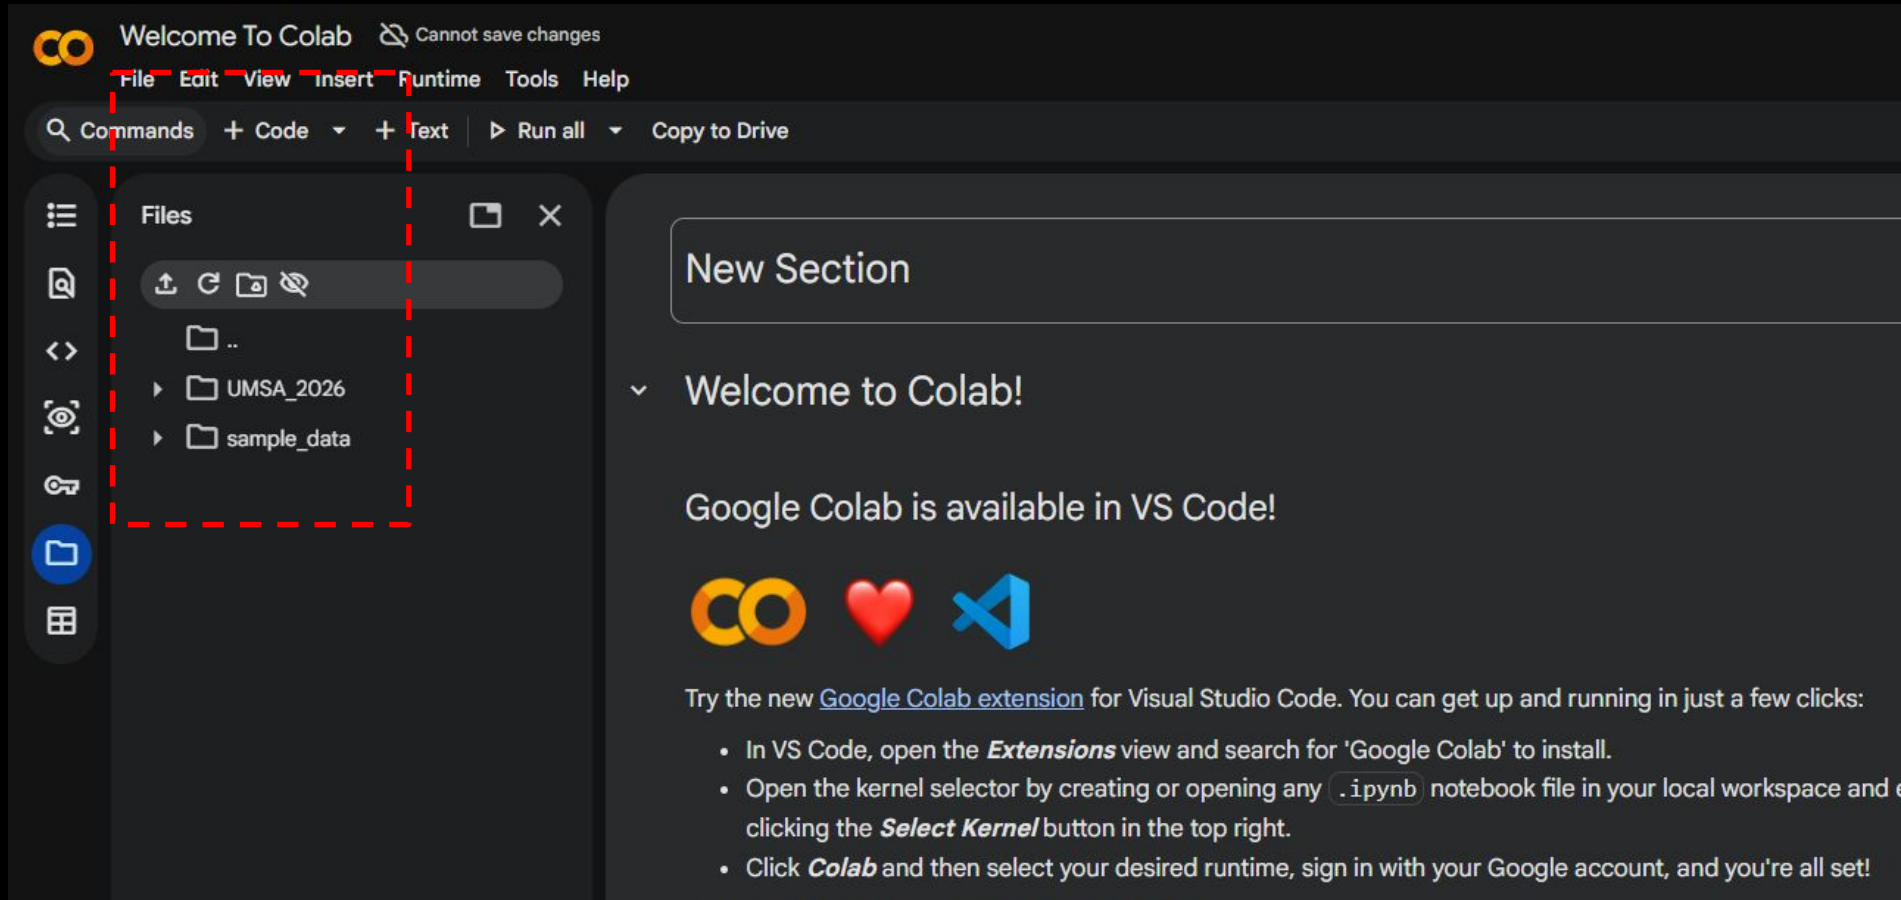
Es necesario crear una cuenta o ingresar con un usuario de Google/GitHub y luego ingresar a Code Online:



Google Colab



Google Colab

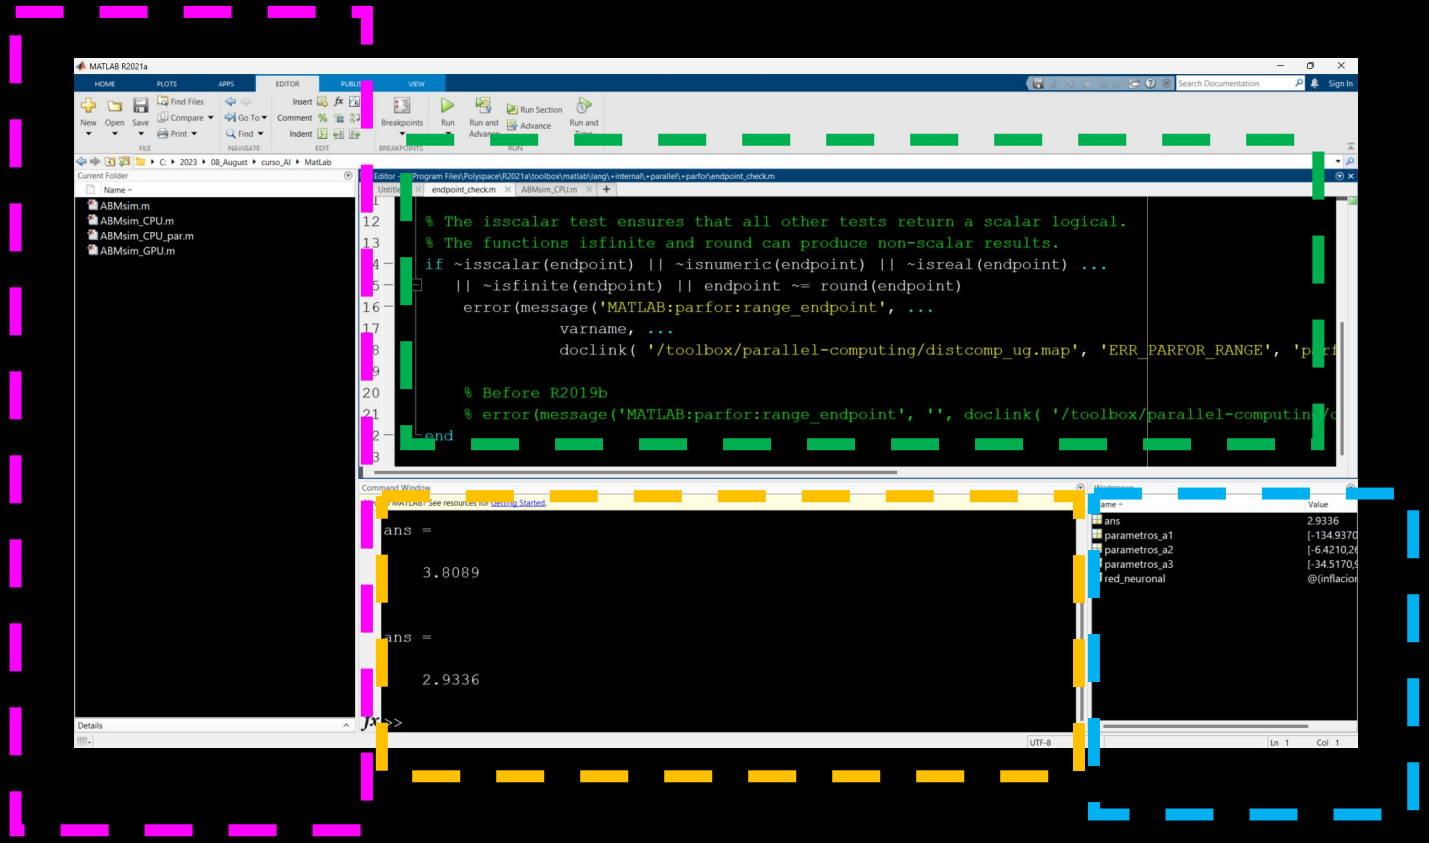


MatLab

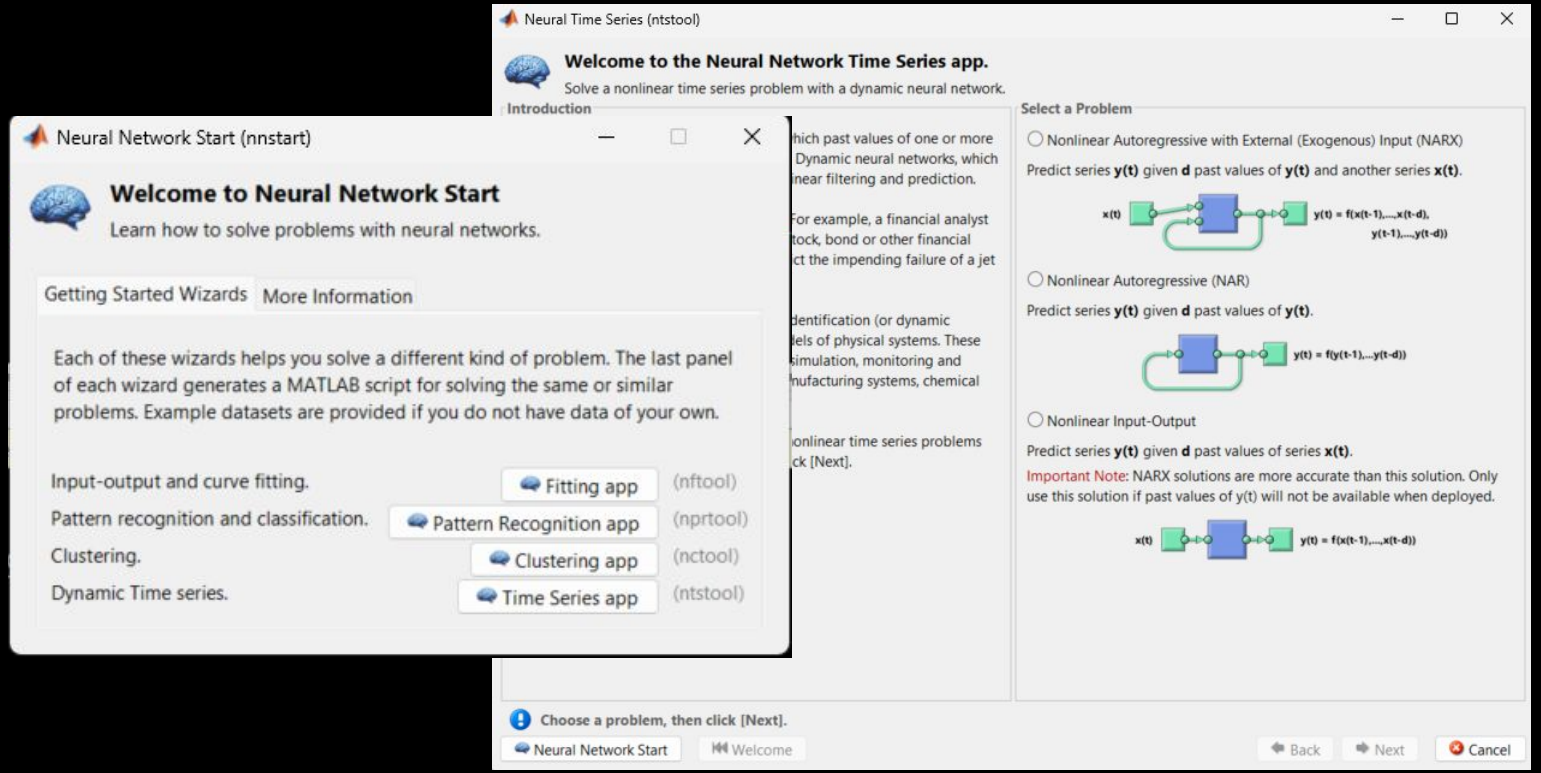
- MATLAB (abreviatura de "Matrix Laboratory") es un entorno de programación y un lenguaje de programación
- Cálculo numérico, análisis de datos, visualización y la simulación.
- Desarrollado por MathWorks
- Ampliamente utilizado en campos como la ingeniería, las ciencias de la computación, las matemáticas aplicadas y otras disciplinas científicas y técnicas.



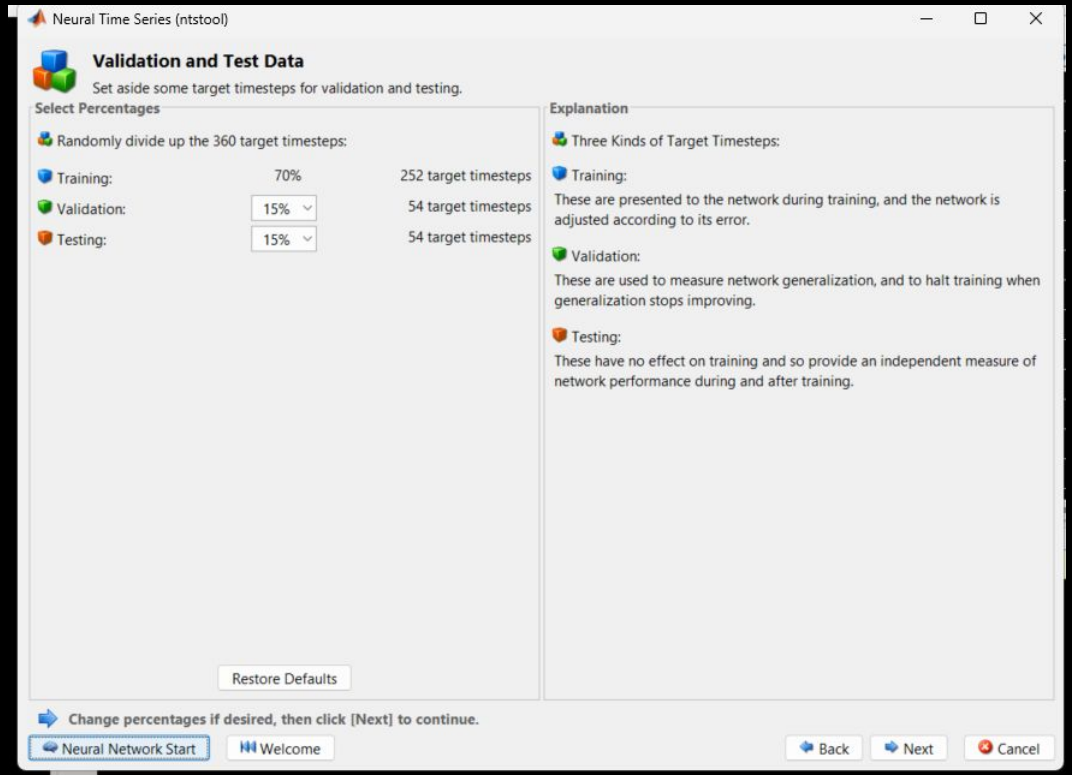
MatLab


MATLAB R2021a
Current Folder
ABMsim.m
ABMsim_CPU.m
ABMsim_CPU_par.m
ABMsim_GPU.m
% The isscalar test ensures that all other tests return a scalar logical.
% The functions isfinite and round can produce non-scalar results.
if ~isscalar(endpoint) || ~isnumeric(endpoint) || ~isreal(endpoint) ...
|| ~isfinite(endpoint) || endpoint ~= round(endpoint)
error(message('MATLAB:parfor:range_endpoint', ...
varname, ...
doclink('/toolbox/parallel-computing/distcomp_ug.map', 'ERR_PARFOR_RANGE', 'p
% Before R2019b
% error(message('MATLAB:parfor:range_endpoint', '', doclink('/toolbox/parallel-computin
end
ans =
3.8089
ans =
2.9336
>>
parametros_a1
parametros_a2
parametros_a3
red_neuronal

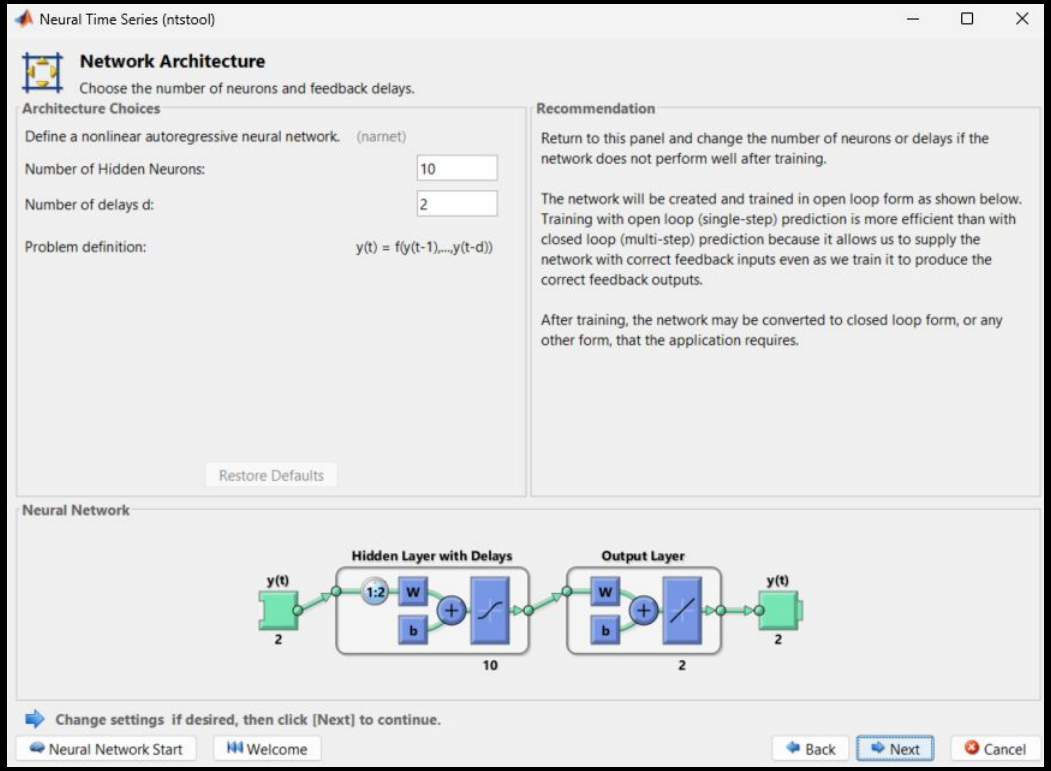
MatLab y redes neuronales artificiales



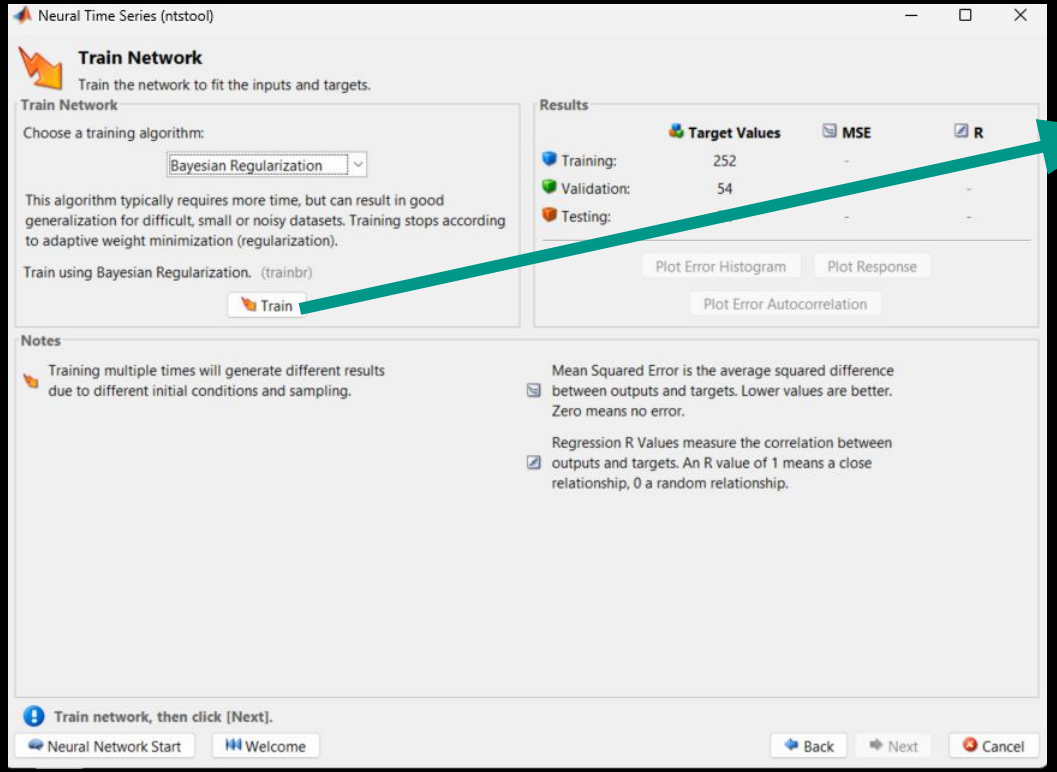
Matlab y Redes Neuronales Artificiales

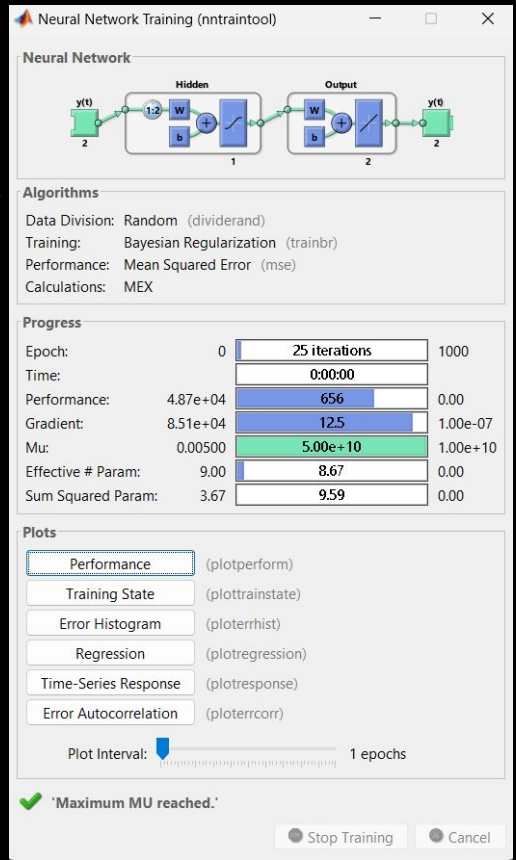


Matlab y Redes Neuronales Artificiales

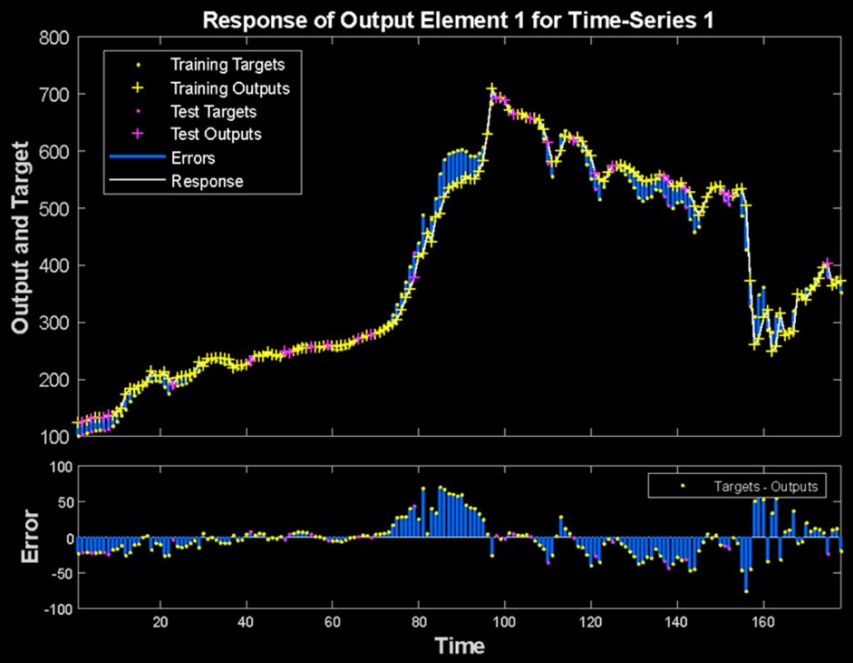


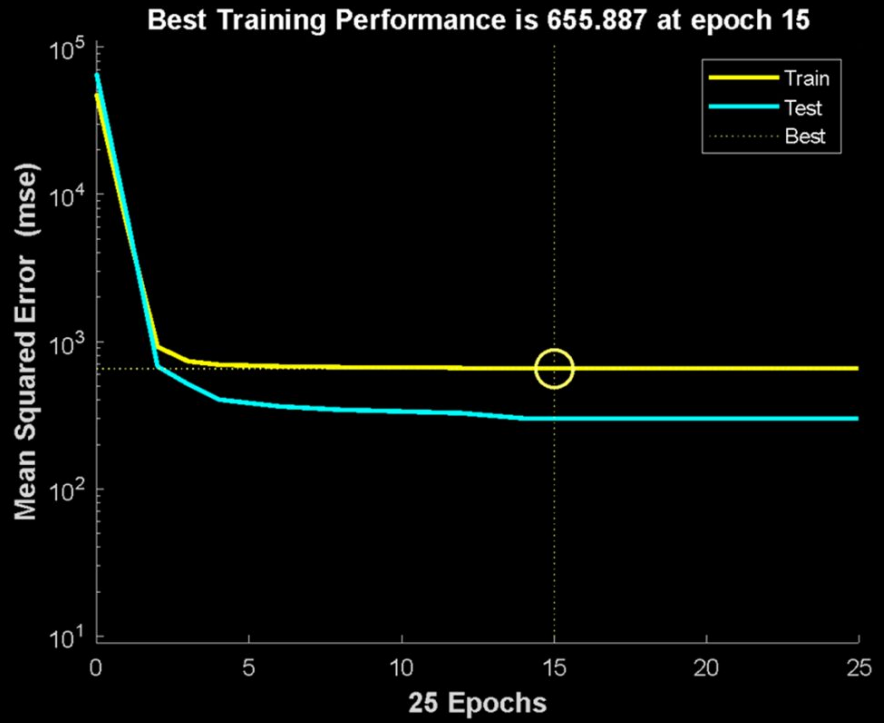
Matlab y Redes Neuronales Artificiales





Matlab y Redes Neuronales Artificiales





Big data

3 V’s:

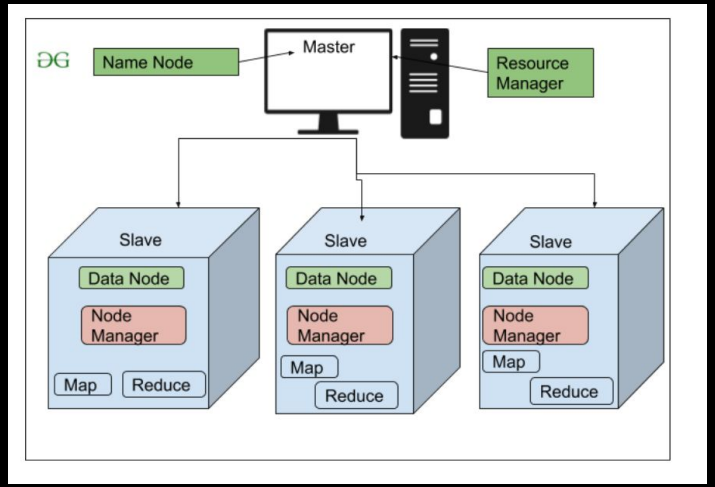
- Volumen: Terabytes, petabytes o incluso exabytes que no pueden ser gestionados o procesados mediante sistemas convencionales (sensores, redes sociales, registros de transacciones)
- Velocidad: se genera a una velocidad increíblemente rápida, en tiempo real o en intervalos muy cortos.
- Variedad: Los datos masivos pueden presentar una amplia variedad de formatos y tipos, como texto, imágenes, audio, vídeo, datos geoespaciales, datos estructurados y no estructurados.



Infraestructura

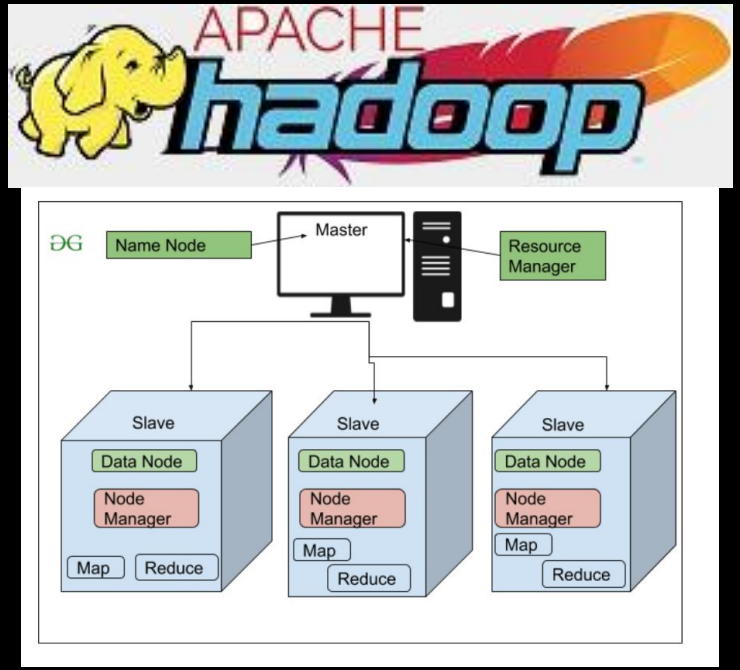
- Apache Hadoop: sistema diseñado para almacenar grandes cantidades de datos en clústeres de servidores. Divide los archivos en bloques y los distribuye a través de los nodos del clúster.
- Estructura maestro-esclavo: El NameNode actúa como el maestro y es responsable de mantener el metadata del sistema de archivos, incluidos los nombres de los archivos, las ubicaciones de los bloques y los permisos. Los DataNodes son los nodos esclavos que almacenan los bloques de datos reales.





Infraestructura

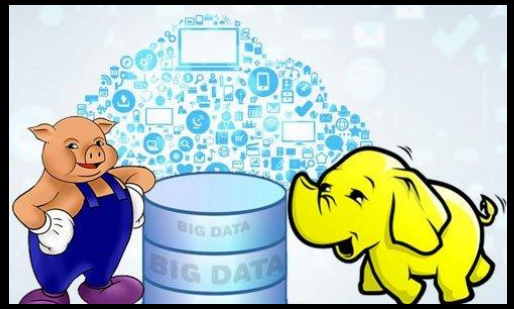
- MapReduce: procesamiento de datos que permite dividir tareas complejas en pasos de "map" y "reduce".
- La fase de "map" implica procesar y filtrar los datos, y la fase de "reduce" se encarga de combinar y resumir los resultados del paso de "map". Esto permite el procesamiento paralelo y distribuido de tareas de análisis de datos en el clúster.



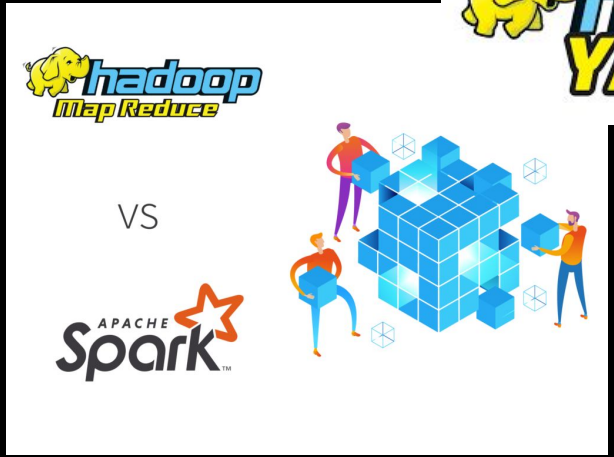
Ecosistema Hadoop

- Hive: Almacenamiento de datos y consulta que permite realizar consultas tipo SQL en datos de almacenamiento distribuido (HDFS).
- Pig: Un lenguaje para realizar transformaciones y análisis de datos en Hadoop.
- Spark: Un sistema de procesamiento de datos en memoria que es más rápido que MapReduce para ciertos tipos de tareas.
- YARN: Un administrador de recursos que permite ejecutar varias aplicaciones en el mismo clúster de manera eficiente.









Opciones a Apache Hadoop

- **Apache Flink:** Admite el procesamiento por lotes. Está diseñado para el procesamiento de baja latencia y alto rendimiento de datos en tiempo real. Las capacidades de procesamiento en tiempo de evento y cálculos con estado hacen que sea adecuado para análisis en tiempo real y aplicaciones que requieren un procesamiento de eventos complejos.
- **Amazon EMR (Elastic MapReduce):** EMR es un servicio gestionado proporcionado por Amazon Web Services (AWS) que simplifica la implementación y administración de marcos de datos grandes, incluidos Hadoop, Spark, Flink y otros. Es una alternativa basada en la nube que te permite crear clústeres y centrarte en el procesamiento de datos sin lidiar con la gestión de la infraestructura.
- **Cloudera:** Cloudera proporciona una plataforma que incluye Hadoop y otras herramientas de datos grandes de código abierto, junto con capacidades de administración y supervisión. Su objetivo es simplificar la implementación y administración de tecnologías de datos grandes y ofrece soluciones tanto en las instalaciones como en la nube.





amazon

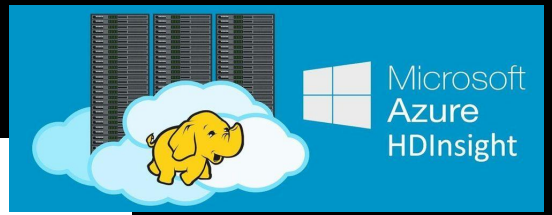
CLOUDERA

Opciones a Apache Hadoop

- **MapR:** MapR ofrece su propia distribución de Hadoop con mejoras adicionales para un mejor rendimiento y confiabilidad. También proporciona capacidades para el procesamiento de datos en tiempo real, el procesamiento de transmisiones y la integración de datos.
- **Google Cloud Dataproc:** Similar a Amazon EMR, Google Cloud Dataproc es un servicio gestionado para ejecutar Apache Hadoop, Spark y otros marcos de datos grandes en Google Cloud Platform.
- **Microsoft Azure HDInsight:** Este es un servicio basado en la nube de Microsoft que ofrece Hadoop, Spark y otras herramientas de datos grandes como un servicio gestionado en la plataforma Azure.
- **IBM BigInsights:** IBM ofrece su propia distribución de Hadoop junto con herramientas adicionales para gobernanza de datos, integración y análisis.







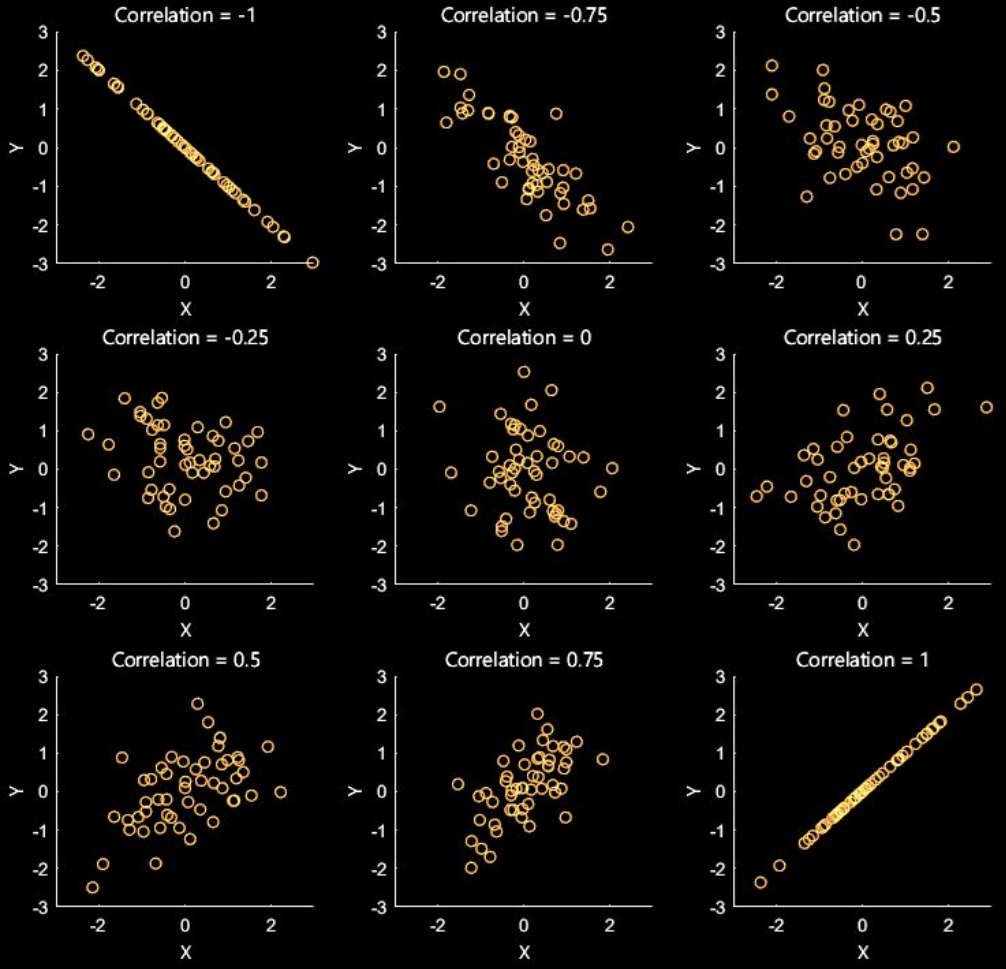


Opciones más accesibles

- Computación paralela (CPU)
- GPU, TPU
- Computación en la nube (CPU, GPU)
- Uso de librerías como Polars



Patrones de Correlación



Correlación no implica causación

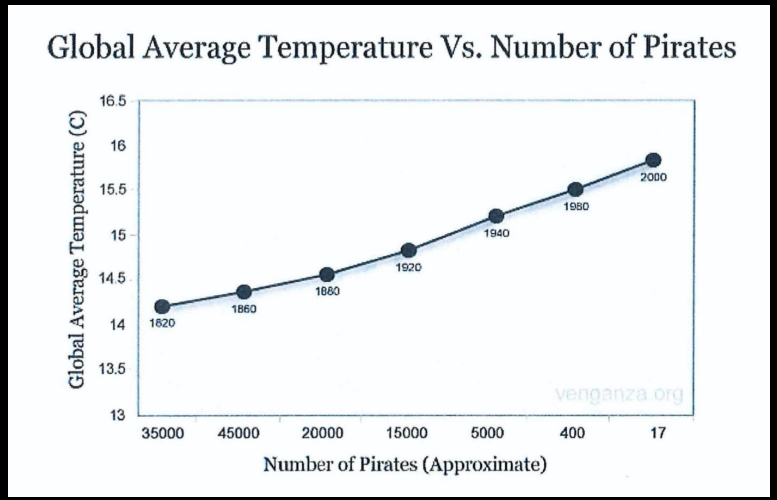
Forbes

LEADERSHIP > CAREERS

True Fact: The Lack of Pirates Is Causing Global Warming

By Erika Andersen, Contributor. Erika Andersen thinks and writes about cre... Follow Author

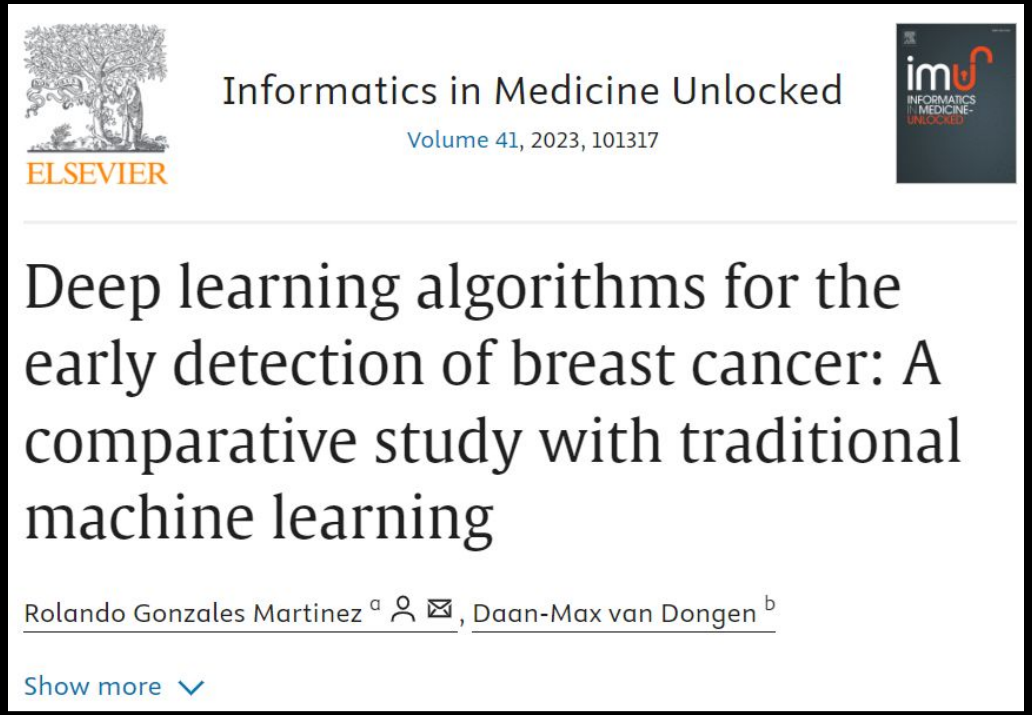
Published Mar 23, 2012, 11:30am EDT, Updated Apr 03, 2012, 10:11pm EDT



Ejemplo de aplicación de aprendizaje profundo: pre-screening de cáncer de mama

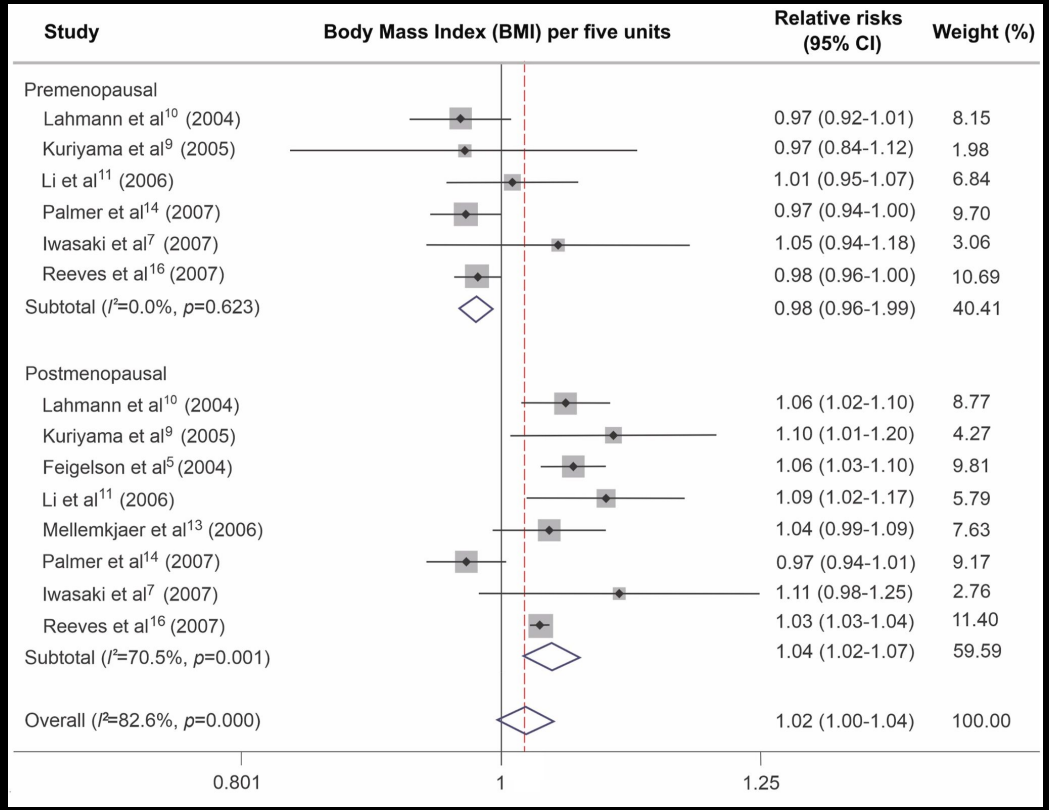
Se comparan modelos/algoritmos de ML con RNA de aprendizaje profundo (deep learning) para el pre-screening de cancer de mama:

https://www.sciencedirect.com/science/article/pii/S2352914823001636?via%3Dihub



Ejemplos de aplicaciones de Deep Learning

- Screening de cancer de mama: mamogramas, biopsias
- Pre-screening: datos demográficos, antropométricos, riesgos relativos (GBD) y obtenidos de muestras de sangre rutinarias



Ejemplos de aplicaciones de Deep Learning

- Screening de cancer de mama: mamogramas, biopsias
- Pre-screening: datos demográficos, antropométricos, riesgos relativos (GBD) y obtenidos de muestras de sangre rutinarias

Table 1
Descriptive statistics of the database.

	mean	std.dev.	min	max
Age (years)	57.30	16.11	24	89
BMI	27.58	5.02	18.37	38.58
Glucose (mg/dL)	97.79	22.53	60.00	201.00
Insulin (μ U/mL)	10.01	10.07	2.43	58.46
HOMA	2.69	3.64	0.47	25.05
Leptin (ng/mL)	26.62	19.18	4.31	90.28
Adiponectin (μ g/mL)	10.18	6.84	1.66	38.04
Resistin (ng/mL)	14.73	12.39	3.21	82.10
RRs [19]	1.51	0.48	0.40	2.44
RRs GBD (center)	1.01	0.10	0.89	1.09
RRs GBD (lower)	0.97	0.08	0.87	1.04
RRs GBD (upper)	1.05	0.11	0.91	1.14
High BMI (binary)	0.34	0.47	0	1
Obesity (binary)	0.32	0.47	0	1

Ejemplos de aplicaciones de Deep Learning

Seleccion de caracteristicas (features):

- Feature selection se realizo con boosting de gradiente extremo.

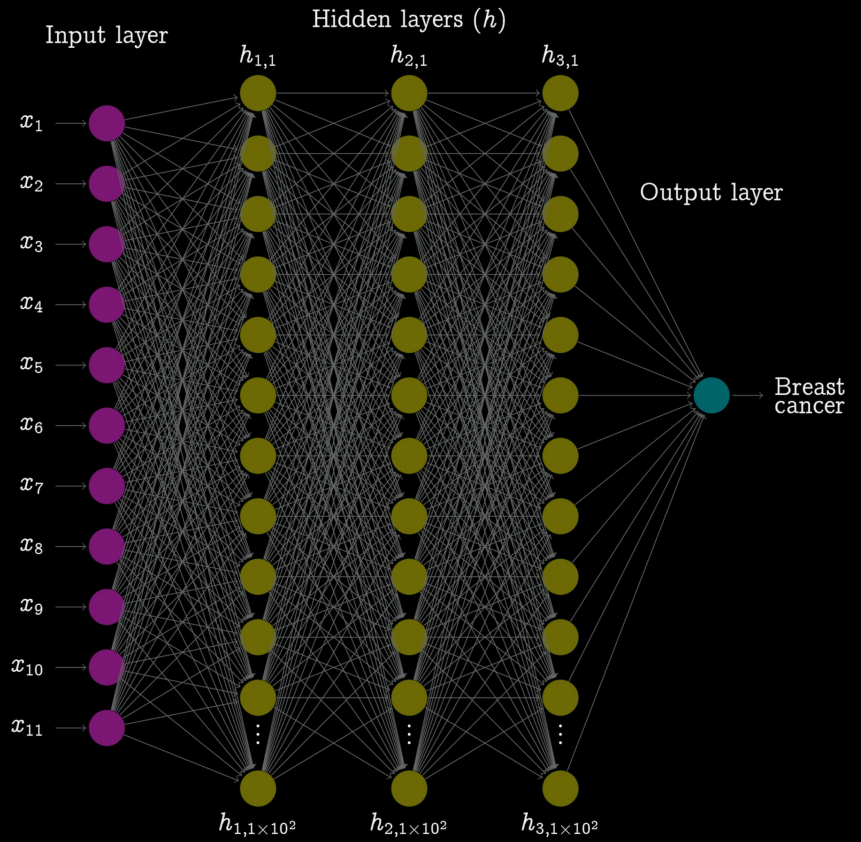
Table 2
Recursive MRMR feature selection with SULOV-gradient boosting.

	description	frequency	min ρ	mean ρ	std.dev. ρ
x_1	Age (years)	97	0.00	0.49	0.28
x_2	Resistin (ng/mL)	90	0.00	0.51	0.28
x_3	RRs GBD (upper)	77	0.05	0.55	0.27
x_4	Glucose (mg/dL)	76	0.21	0.59	0.22
x_5	Adiponectin (μ g/mL)	75	0.23	0.60	0.22
x_6	High BMI (binary)	65	0.27	0.64	0.20
x_7	MCP-1 (pg/dL)	65	0.26	0.65	0.19
x_8	Leptin (ng/mL)	64	0.30	0.65	0.19
x_9	RRs [19]	59	0.37	0.68	0.17
x_{10}	Obesity (binary)	59	0.11	0.55	0.28
x_{11}	Insulin (μ U/mL)	33	0.05	0.53	0.26
	BMI	30	0.62	0.81	0.11
	HOMA	29	0.69	0.83	0.09
	RRs GBD (center)	8	0.86	0.90	0.04
	RRs GBD (lower)	8	0.21	0.81	0.25

Ejemplos de aplicaciones de Deep Learning

En la arquitectura de la red neuronal profunda:

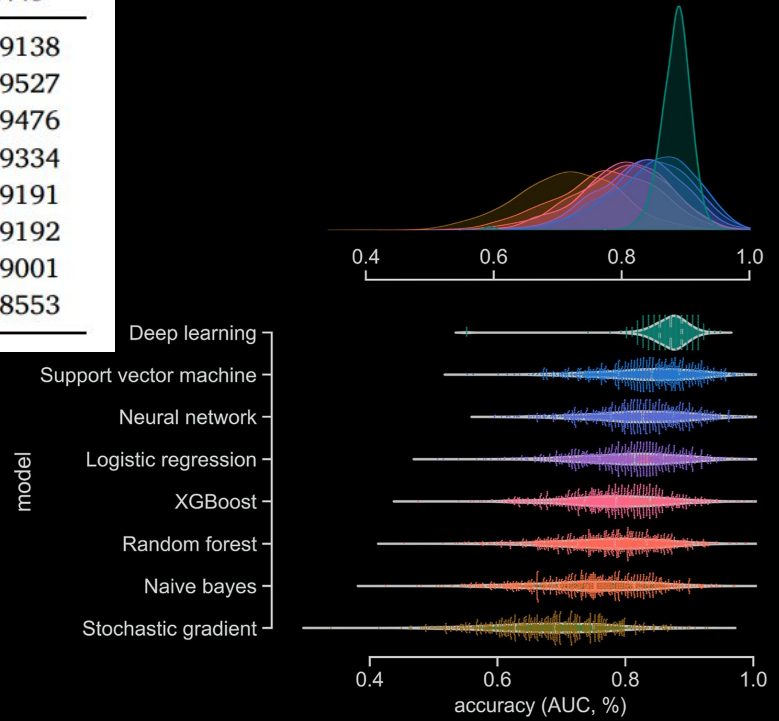
- Funciones de activación lineal rectificadas (ReLU)
- 3 capas ocultas
- 102 nodos en cada capa oculta, con regularizadores L1 y L2 para evitar el sobreajuste



Ejemplos de aplicaciones de Deep Learning

Table 3
AUC of the machine learning and deep learning algorithms.

Model	mean	std.dev.	p2.5	p97.5
Deep learning	0.8699	0.0345	0.8190	0.9138
Support vector machines	0.8344	0.0711	0.6768	0.9527
Neural network	0.8232	0.0720	0.6667	0.9476
Logistic regression	0.8078	0.0741	0.6569	0.9334
XGBoost	0.7834	0.0755	0.6263	0.9191
Random forest	0.7763	0.0804	0.6035	0.9192
Naive bayes	0.7504	0.0869	0.5686	0.9001
Stochastic gradient	0.6861	0.0860	0.5120	0.8553



Ejemplos de aplicaciones de Deep Learning

Table 4
Performance metrics based on the confusion matrix.

Model	Derivations from confusion matrix*					
	TPR	TNR	FNR	FPR	FDR	FOR
Deep learning	0.9220 (0.0597)	0.8021 (0.1118)	0.0780 (0.0597)	0.1979 (0.1118)	0.1425 (0.0522)	0.0983 (0.0655)
SVM	0.7939 (0.1183)	0.6747 (0.1381)	0.2061 (0.1183)	0.3253 (0.1381)	0.2501 (0.1065)	0.2672 (0.1399)
Neural network	0.7638 (0.1148)	0.7135 (0.1324)	0.2362 (0.1148)	0.2865 (0.1324)	0.2331 (0.1051)	0.2851 (0.1284)
Logistic regression	0.7329 (0.1243)	0.7311 (0.1292)	0.2671 (0.1243)	0.2689 (0.1292)	0.2291 (0.108)	0.3055 (0.1319)
XGBoost	0.7537 (0.1158)	0.6723 (0.1342)	0.2463 (0.1158)	0.3277 (0.1342)	0.2604 (0.1029)	0.3061 (0.1327)
Random forest	0.6892 (0.1267)	0.7038 (0.1365)	0.3108 (0.1267)	0.2962 (0.1365)	0.2575 (0.1144)	0.3477 (0.1263)
Naive bayes	0.5313 (0.1296)	0.8023 (0.1131)	0.4687 (0.1296)	0.1977 (0.1131)	0.2303 (0.126)	0.4147 (0.1083)
Stochastic gradient	0.7126 (0.1394)	0.6518 (0.1587)	0.2874 (0.1394)	0.3482 (0.1587)	0.2792 (0.1106)	0.3412 (0.1409)

(*) TPR: True positive rate, TNR: true negative rate, FNR: false negative rate, FPR: false positive rate, FDR: false detection rate, FOR: false omission rate. Rates are averages of the 1×10^3 k-fold cross validations. Standard deviations in brackets below each average rate. SVM: Support Vector Machines.

Logística y objetivos de aprendizaje

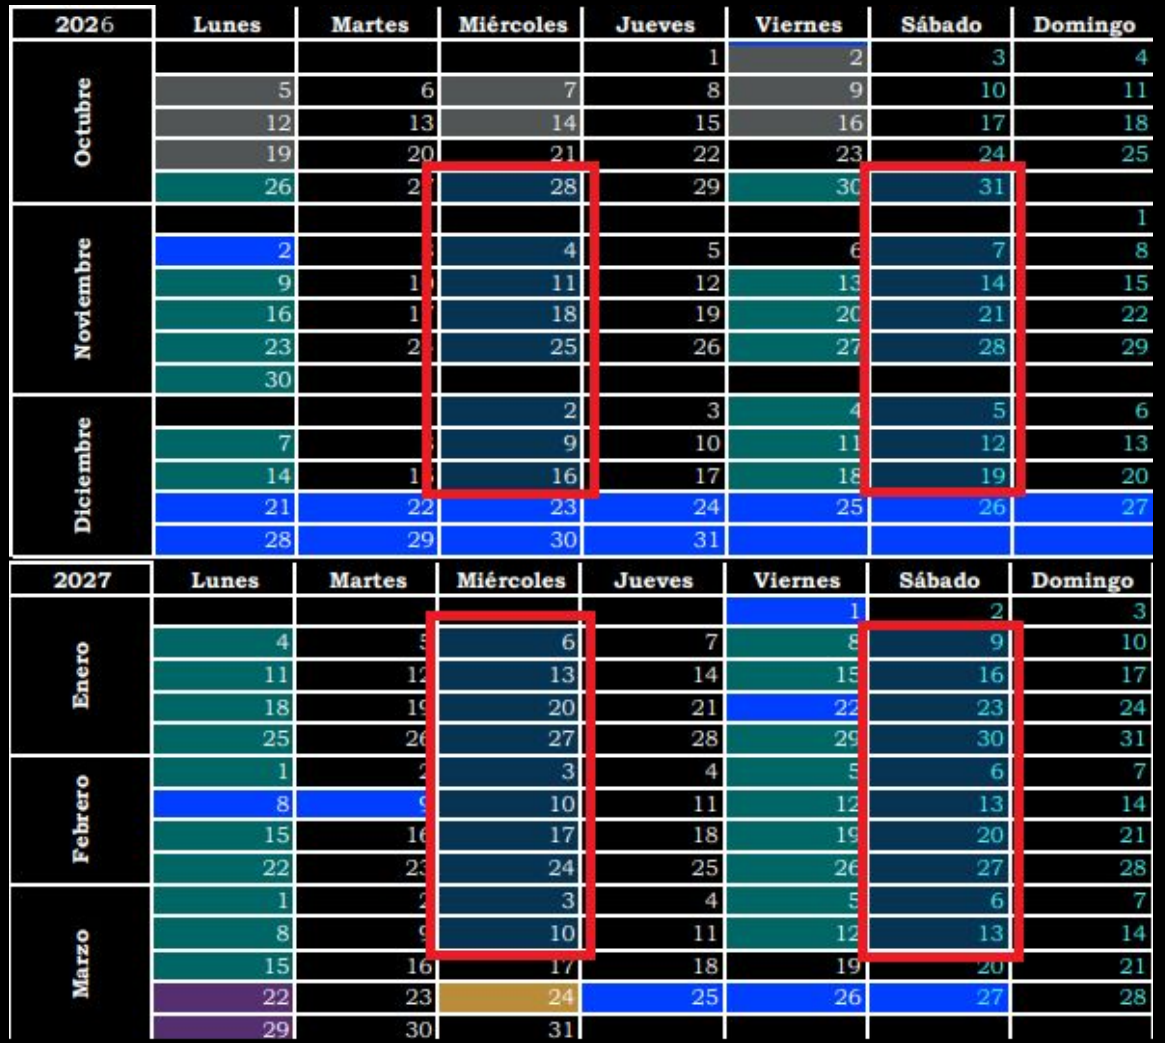
Tensores

- Un tensor es un objeto matemático que generaliza las nociones de escalar, vector y matriz a dimensiones o arreglos de orden superior del sistema de coordenadas.
- Los tensores se definen y analizan para aplicaciones estadísticas y de aprendizaje automático

Clases programadas

28 de Octubre 2026 a 13 de marzo de 2027

36 sesiones:
Octubre (2),
Noviembre (8),
Diciembre (6),
Enero (8),
Febrero (8),
Marzo (4)



2026	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
Octubre				1	2	3	4
	5	6	7	8	9	10	11
	12	13	14	15	16	17	18
	19	20	21	22	23	24	25
	26	27	28	29	30	31	
Noviembre							1
	2	3	4	5	6	7	8
	9	10	11	12	13	14	15
	16	17	18	19	20	21	22
	23	24	25	26	27	28	29
	30						
Diciembre			2	3	4	5	6
	7	8	9	10	11	12	13
	14	15	16	17	18	19	20
	21	22	23	24	25	26	27
	28	29	30	31			

2027	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
Enero					1	2	3
	4	5	6	7	8	9	10
	11	12	13	14	15	16	17
	18	19	20	21	22	23	24
	25	26	27	28	29	30	31
Febrero	1	2	3	4	5	6	7
	8	9	10	11	12	13	14
	15	16	17	18	19	20	21
	22	23	24	25	26	27	28
Marzo	1	2	3	4	5	6	7
	8	9	10	11	12	13	14
	15	16	17	18	19	20	21
	22	23	24	25	26	27	28
	29	30	31				

Clases programadas

28 de Octubre 2026 a
13 de marzo de 2027

Horarios de clase

Miércoles:
19 a 21:30 (Grabaciones)

Sábados:
8 AM a 10:30 AM
(Hora de Bolivia)
2 PM a 4:30 PM
(Hora de Alemania)

2026	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
Octubre				1	2	3	4
	5	6	7	8	9	10	11
	12	13	14	15	16	17	18
	19	20	21	22	23	24	25
	26	27	28	29	30	31	
Noviembre							1
	2	3	4	5	6	7	8
	9	10	11	12	13	14	15
	16	17	18	19	20	21	22
	23	24	25	26	27	28	29
	30						
Diciembre			2	3	4	5	6
	7	8	9	10	11	12	13
	14	15	16	17	18	19	20
	21	22	23	24	25	26	27
	28	29	30	31			

2027	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
Enero					1	2	3
	4	5	6	7	8	9	10
	11	12	13	14	15	16	17
	18	19	20	21	22	23	24
	25	26	27	28	29	30	31
Febrero	1	2	3	4	5	6	7
	8	9	10	11	12	13	14
	15	16	17	18	19	20	21
	22	23	24	25	26	27	28
Marzo	1	2	3	4	5	6	7
	8	9	10	11	12	13	14
	15	16	17	18	19	20	21
	22	23	24	25	26	27	28
	29	30	31				

Políticas académicas

Evaluación y calificación

- Cada materia debe evaluarse sobre 100 puntos (100%).
- La nota mínima de aprobación es de 70 puntos (70%).
- Si un estudiante no alcanza el puntaje mínimo, tiene derecho a una segunda oportunidad: Si la materia se evaluó mediante examen, podrá rendir un examen recuperatorio. Si se evaluó mediante trabajo, podrá presentar una versión mejorada del mismo. El plazo para esta segunda instancia será de 2 a 3 semanas posteriores a la primera evaluación.

Asistencia

- Se requiere un mínimo de 80% de asistencia en cada materia.
- Aunque las clases son virtuales y se graban, se solicita fomentar la participación activa para evitar que la maestría se convierta únicamente en un repositorio de videos.
- Se recomienda aplicar estrategias que motiven a los estudiantes a asistir en tiempo real.

Evaluación de la clase

- Prácticas en clase: 4 × 10 puntos = 40 puntos
- Participación en clase: 15 puntos
- Examen de preguntas cerradas (respuesta múltiple): 20 puntos (Febrero-Marzo 2027)
- Trabajo práctico individual o en grupo (max 2): 25 puntos, presentación: Febrero-Marzo 2027

Información de contacto

WhatsApp: +31 6 31171933

Email:
r.m.gonzales.martinez@rug.nl
gonzalesmartinez@gmail.com

GitHub:
https://github.com/rogon666/UCB2026

Contenido del curso

Contenido mínimo (UCB):

- Introducción a Redes Neuronales. Redes Neuronales Feed-Forward (MLP). Redes Neuronales Recurrentes.
- Redes Neuronales Convolucionales
- Autoencoders.

Contenido del curso

Parte I: Introducción y homogeneización

1) Breve historia y perspectivas de la inteligencia sintética
2) Aprendizaje supervisado, no supervisado, y de re-enforzamiento
3) Inteligencia artificial y redes neuronales artificiales (RNA): Fundamentos biológicos
4) Arquitecturas de RNA y aprendizaje profundo
5) Homogeneización (conceptos clave en algebra matricial, probabilidad y estadística)

Contenido del curso

Parte II: Shallow neural networks (SNNs)

1) Perceptrón de una sola capa
2) Perceptrón multicapa
3) Redes neuronales feed-forward
4) Funciones de activación comunes
5) Teorema de aproximación universal
6) Redes neuronales convolucionales
7) Redes neuronales recurrentes (LSTM, GRU)
8) SNNs para resolver problemas de regresión y clasificación

Contenido del curso

Parte III: Deep neural networks

1) Aprendizaje de re-enforzamiento: procesos de decisión de Markov
2) Métodos de regularización y optimización
3) “Tuneo” de hiperparametros
4) La arquitectura de Transformers
5) Pre-entrenamiento de gran escala con Transformers
6) Procesamiento del lenguaje natural
7) Redes neuronales adversarias
8) Redes convolucionales profundas
9) Autoencoders

Bibliografia

Neural Networks and Deep Learning:
http://neuralnetworksanddeeplearning.com/

Understanding deep learning:
https://udlbook.github.io/udlbook/

Dive into deep learning:
https://arxiv.org/pdf/2106.11342

Objetivos de aprendizaje

Desarrollar habilidades para analizar datos con ML (RNA) y DL, en teoría y en la práctica.

- Comprender qué herramientas están disponibles.
- Entender cuándo usar esas herramientas.
- Saber cómo usar esas herramientas.

¿Cuáles son sus objetivos?
¿Qué herramientas les gustaría discutir y aplicar en la clase?



Visión de enseñanza y aprendizaje en la clase

Discutir y cubrir el material relacionado con técnicas de machine learning (RNA) básicas, conocidas y comúnmente aplicadas, pero también métodos en las fronteras de la ciencia—en el marco del UDL, la pirámide de Miller y la taxonomía de Bloom—mediante el alineamiento constructivo y el aprendizaje activo:

> "*Learning [...] has to enable us to work at the boundary of what we know or [...] to go beyond those boundaries, or even reconstruct the very framework of our knowledge.*"

Fear of a Black Universe (p. 6, ch. 1, Escape From the Jungle of No Imagination), Stephon Alexander, 2021

Alineamiento constructivo (objetivos SMART)

Objetivos de aprendizaje conceptuales (conocimientos) y de habilidades prácticas

Meta dónde queremos llegar

2MP



Para saber que llegamos donde queremos llegar

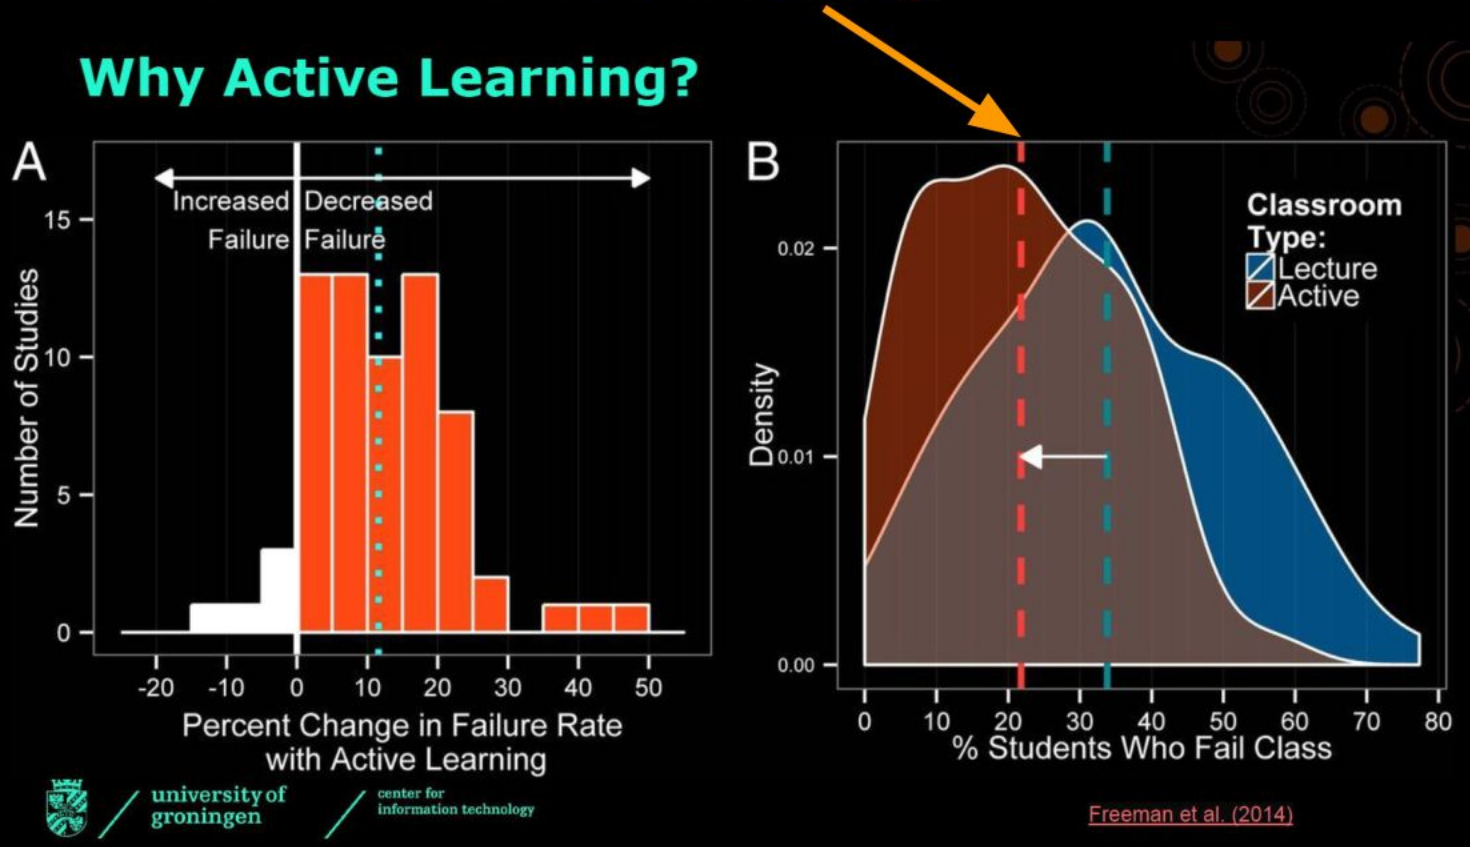
Actividades de evaluación de la adquisición de conocimientos y habilidades

Actividades prácticas de aprendizaje (laboratorios)



Practicar conceptos y habilidades para llegar a la meta

Aprendizaje activo (active learning)



UDL: Diseño universal para el aprendizaje inclusivo

No hay un solo método de enseñanza que sea eficaz para tod@s, por lo que se deben ofrecer múltiples formas de representación, expresión e involucramiento (engagement)

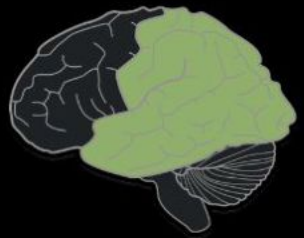
AFFECTIVE NETWORKS:
THE **WHY** OF LEARNING



Engagement

For purposeful, motivated learners, stimulate interest and motivation for learning.

RECOGNITION NETWORKS:
THE **WHAT** OF LEARNING



Representation

For resourceful, knowledgeable learners, present information and content in different ways.

STRATEGIC NETWORKS:
THE **HOW** OF LEARNING



Action & Expression

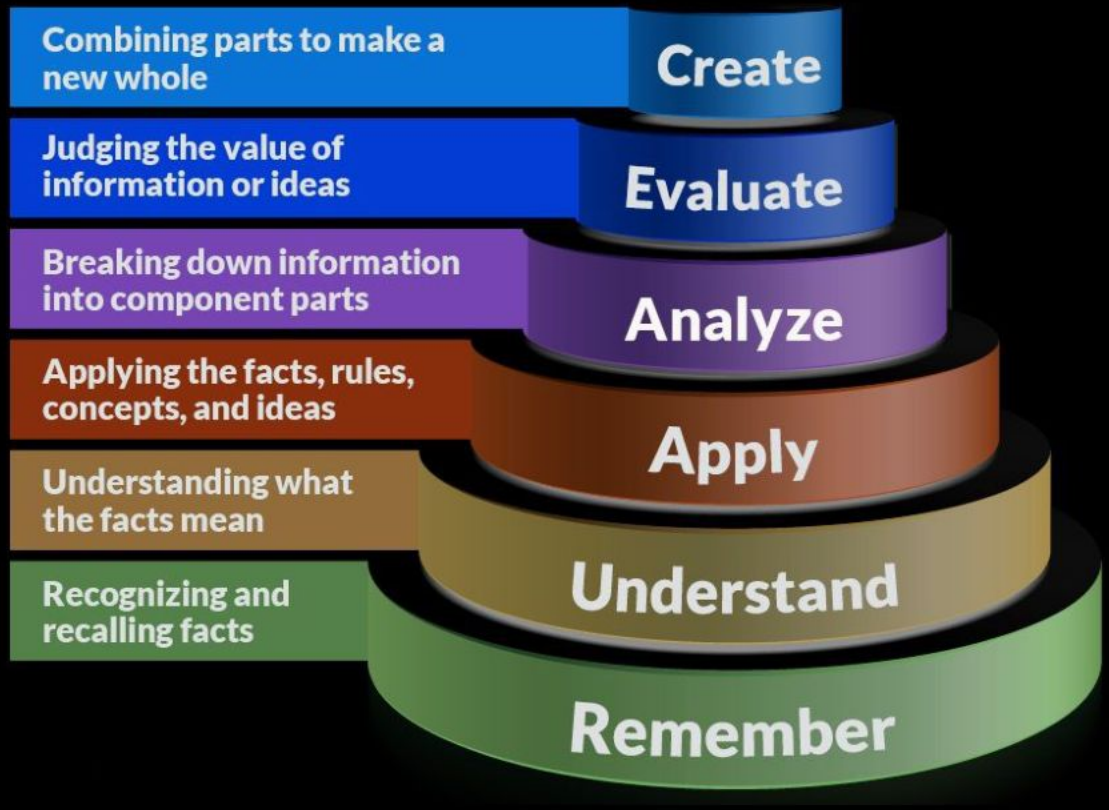
For strategic, goal-directed learners, differentiate the ways that students can express what they know.

Pirámide de Miller para para medir el progreso en la adquisición de habilidades y conocimientos



C: Conocimiento conceptual
H: Habilidad
A: Actitudes (valores, comportamientos y enfoques éticos)

La Taxonomía de Bloom para esta clase de maestría



Versión revisada para incluir el conocimiento*:

- Factual
- Conceptual
- Procedural
- Metacognitivo

(*) Anderson, L. W., Krathwohl, D. R., & Bloom, B. S. (2001). A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives. New York: Longman.

Conocernos en clase

Investigador de la Universidad de Oxford y fellow post-doctoral [Käte Hamburger Centre for Apocalyptic and Post-Apocalyptic Studies (CAPAS)]

https://ophi.org.uk/people/rolando-gonzales-martinez

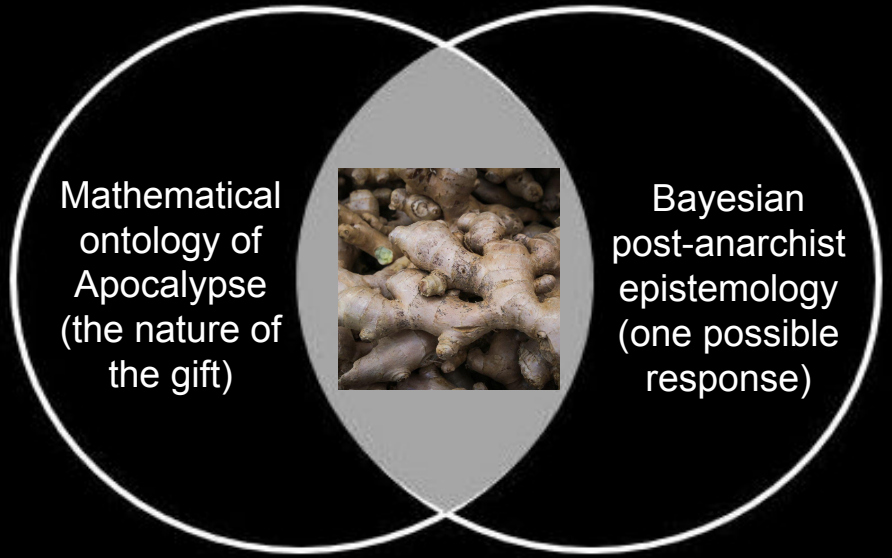
https://www.capas.uni-heidelberg.de/en/fellowships/current-fellows-2025-2026/rolando-gonzales-martinez

Introduction: Phenomenology of Apocalypse

Phenomenology of Apocalypse: the givenness

Based on Folger's* interpretation of Jean-Luc Marion's phenomenology:

- Apocalypse is dialectic and a particular class of phenomena: a saturated phenomena, a phenomena "in excess": an overwhelming singularity without comparison
- Apocalypse as a "gift" that is given to a subject. A gift that requires a ***response*** (event and response are constitutive of the phenomenon)



*Robert Folger. Archaeologies of apocalypse: A preface. Apocalyptica, 1(1):19–35, Sep 2022. doi: 10.17885/heiup.apoc.2022.1.24603. URL https://heiup.uni-heidelberg.de/journals/apocalyptica/article/view/24603.

Phenomenology of Apocalypse: the response

Responses:

1. Accept the gift: a subjective (individual) response of accepting the “end” of our world as a destruction of our personal and individual way of living, and looking forward for a revelation to “transform” ourselves and move to the a next (post-apocalyptic) ”world” (Ayahuasca rituals)
2. Deny the gift: resistance and rebellion against the forces and entities that are precipitating the end of world(s).

Bayesian post-anarchist epistemology = epistemic explosive devices of collective resistance and rebellion aimed to fight against the forces precipitating apocalypse

Mathematical ontology of Apocalypse (the nature of the gift)



Bayesian post-anarchist epistemology (one possible response)

Part 1 of 2: The Gift

(A Mathematical ontology of Apocalypse)

Mathematical ontology of Apocalypse: What is the “gift”? A scalar-gradient model

$$C_\eta(\mathbf{x};\boldsymbol{\lambda}) = \sum_{i\in I} C_i(x_i;\lambda_i) + \eta W(\mathbf{x};\boldsymbol{\lambda})$$

$$H_\eta = \nabla^2_{\mathbf{x}} C_\eta = \begin{pmatrix} H_{11} & H_{12} & \cdots & H_{1I} \\ H_{21} & H_{22} & \cdots & H_{2I} \\ \vdots & \vdots & \ddots & \vdots \\ H_{I1} & H_{N2} & \cdots & H_{II} \end{pmatrix}$$

$$\eta = 0 \qquad \mathcal{M}_0^{(I)} = \prod_{i\in I} \mathcal{M}_i.$$

$$\mathcal{M}_{\mathcal{A}} := \mathcal{M}_{\mathcal{A}}^{(I)} = \left\{(\mathbf{x}_I, \boldsymbol{\lambda}_I) : \nabla_{\mathbf{x}_I} C_\eta^{(I)} = 0\right\} \qquad |I| \geq 2.$$

$$\mathcal{E}_{\mathcal{A}}: \quad \mathbf{x}^- \xrightarrow{p_{\mathcal{A}} \in \Sigma_{\mathcal{A}}} \mathbf{x}^+, \qquad \mathbf{x}^+ \not\asymp \mathbf{x}^-$$

$$\Sigma_{\mathcal{A}} := \Sigma_{\mathcal{A}}^{(I)} = \left\{(\mathbf{x}_I, \boldsymbol{\lambda}_I) \in \mathcal{M}_{\mathcal{A}}^{(I)} : \det H_{\eta,I}(\mathbf{x}_I, \boldsymbol{\lambda}_I) = 0\right\}$$

$$A_\omega(\mathbf{y};\boldsymbol{\alpha}) = \sum_{r\in R} A_r(y_r;\alpha_r) + \omega Z(\mathbf{y};\boldsymbol{\mu})]$$

$$H^{\aleph}_{rs} = \nabla^2_{\mathbf{y}_r\mathbf{y}_s} A_\omega = \omega \nabla^2_{\mathbf{y}_r\mathbf{y}_s} Z, \qquad r \neq s.$$

$$H^{\aleph}_{rs} \not\equiv 0. \qquad R > 2$$

$$\mathcal{M}_{\aleph} = \{(\mathbf{y},\boldsymbol{\alpha}) : \nabla_{\mathbf{y}} A_\omega(\mathbf{y};\boldsymbol{\alpha}) = 0\}$$

$$\Sigma_{\aleph} = \{(\mathbf{y},\boldsymbol{\alpha}) \in \mathcal{M}_{\aleph} : \det H_{\aleph}(\mathbf{y},\boldsymbol{\alpha}) = 0\}$$

$$\mathcal{E}_{\aleph}: \quad \mathbf{y}^- \xrightarrow{\Sigma_{\aleph}} \mathbf{y}^+, \qquad \mathbf{y}^+ \not\asymp \mathbf{y}^-$$

Mathematical ontology of Apocalypse: theological and existential considerations

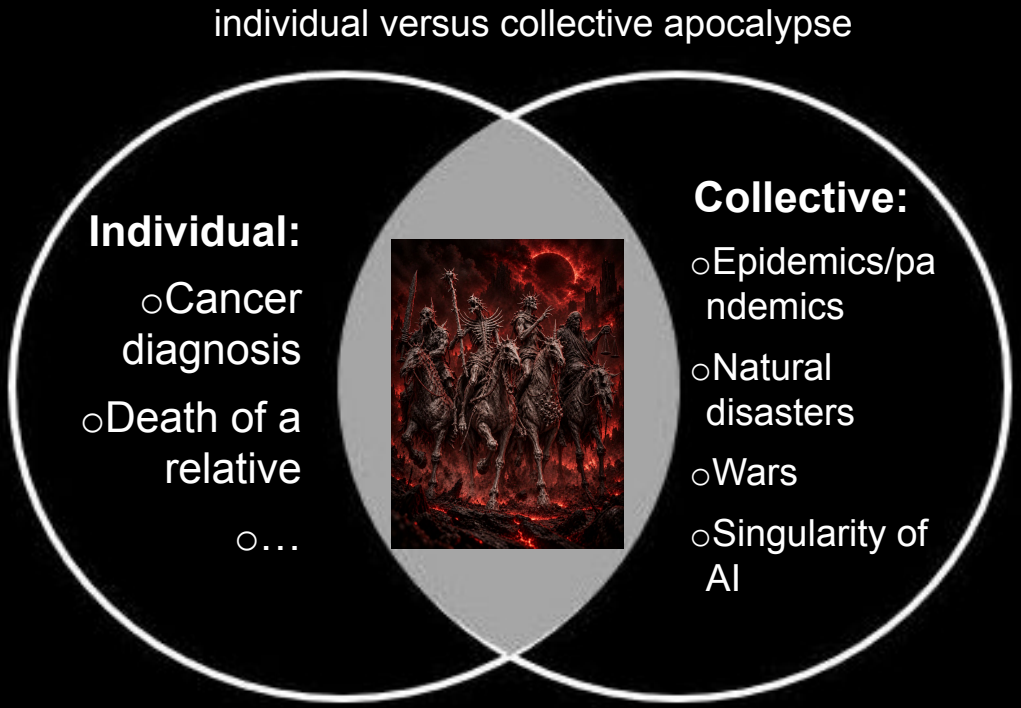
- The mathematical ontology of Apocalypse is not theological (God does not enter the equations), but it is agnostic (does not deny or accept the existence of god; god simply does not enter the equations).
- The mathematical ontology of Apocalypse is impersonal in the sense of lacking a subject: it only formalizes the “gift” of Apocalypse
- The subject is the being to who the gift is given (and that must respond to this gift, there is no freedom of not responding).



Sisyphus - Antonio Zanchi (1631-1722)

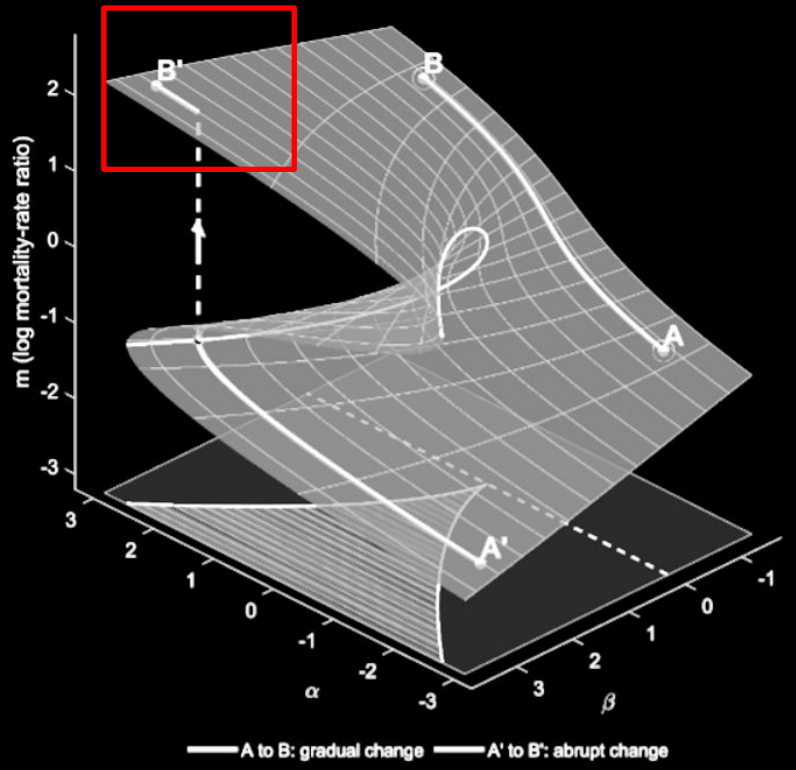
Mathematical ontology of Apocalypse: the scalar-gradient model captures multiples scale of apocalyptic events

The scale of this gift (the scale of apocalyptic events, that is, the scale of coupled catastrophic events) can be macro/meso/micro/nano (affecting the whole world, as a pandemic, or only a country, sub-national region, community, a family or the own world of a single individual), and in that sense can be individual or collective

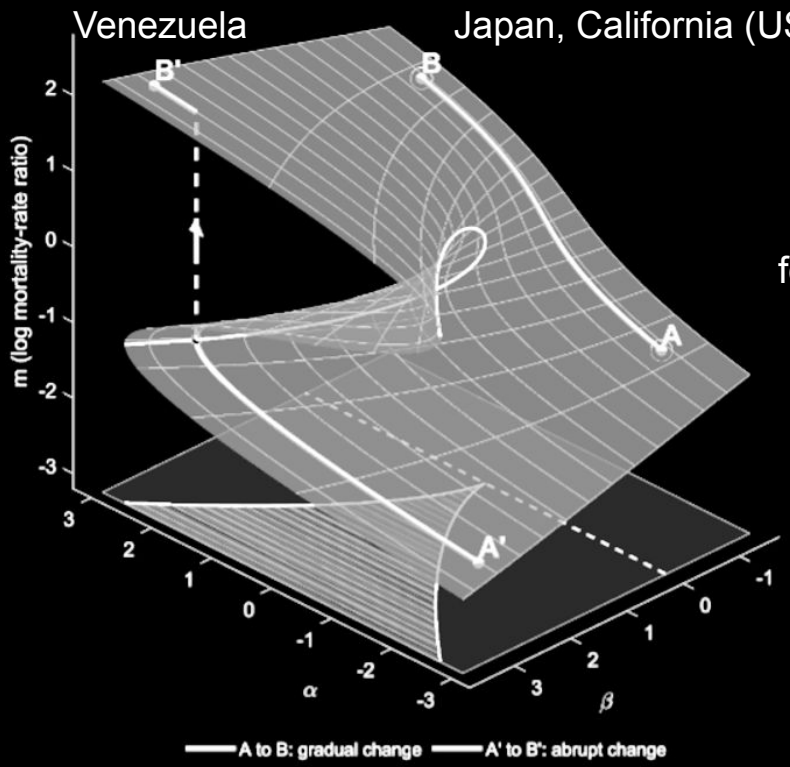


Mathematical ontology of Apocalypse: What is the “gift”? A scalar-gradient model, intensity of apocalyptic events

- The scalar-gradient model of the mathematical ontology of Apocalypse assumes that the events (catastrophic or apocalyptic) have been intense enough (in combination with other intrinsic factors, as vulnerability) to cause a transition in the state-space, towards a singularity



Mathematical ontology of Apocalypse
Empirical illustration: catastrophic mortality



June 24–25, 2026, four major (unrelated) earthquakes struck three different continents within a roughly 8-to-12-hour window



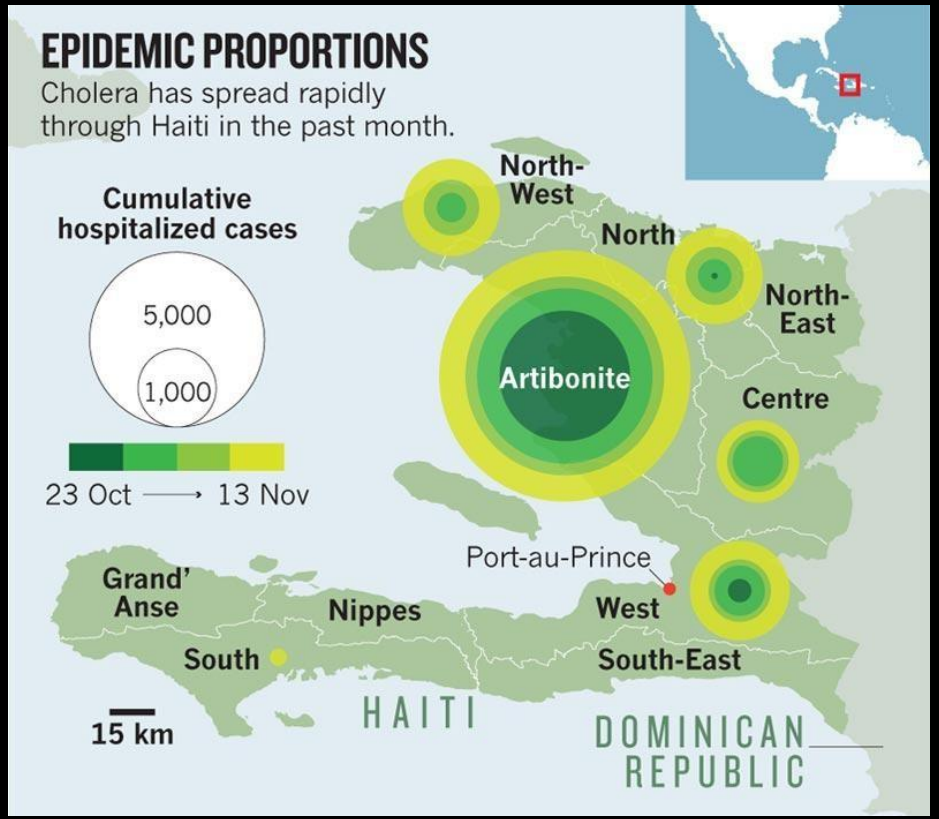
Mathematical ontology of Apocalypse
Empirical illustration: apocalyptic morbidity and mortality

2010 Haiti:

- *Goudougoudou* (M7 earthquake and 52+, January)
- Cholera epidemic (~October)







Mathematical ontology of Apocalypse
Empirical extensions

- The coupling based on the off-diagonal elements of the Hessian assumes symmetric coupling, asymmetric empirical dynamics (the effect of an epidemic happening during a war is not the same as of a war happening during an epidemic) can be captured/formalized through generalized gradient systems and/or the Jacobian matrix of a general vector field
- Connection to chaos theory: the generalized vector-field extension can generate chaotic dynamics and chaotic attractors, besides periodic oscillations.

Mathematical ontology of Apocalypse
Empirical extensions

- Instead of using a collection set of $I \geq 2$ of catastrophes, it is possible to use a single catastrophe with state-space parameters that map multiple hazards.
- This idea could work on an individual-scale but not on collective-scale events (wars, epidemics/pandemics, natural disasters), because it will assume similar

Mathematical ontology of Apocalypse
Empirical extensions

- The coupling parameters $\eta \in \mathbb{R}$, $\omega \in \mathbb{R}$ can be different from zero ($\eta \neq 0$, $\omega \neq 0$) due to spatiotemporal synchronization (can be formalized with spatially coupled reaction–diffusion systems) or due to socio-economic factors (population vulnerability)

Part 2 of 2: The Response

Part 2 of 2: The Response

Response 1: Experiments with Ayahuasca

Experiments with Ayahuasca: An autoethnography

Ayahuasca: South American psychoactive (hallucinogenic) decoction prepared from *Banisteriopsis caapi* vine and a dimethyltryptamine (DMT)-containing plants, used by indigenous cultures as part of traditional medicine and shamanism.



Autoethnography: own personal experience as primary data

- Instead of observing others from the outside, I reflect on my own memories, emotions, and experiences.
- It embraces subjectivity: my own

Part 2 of 2: The Response

Response 2: A Bayesian Post-anarchist epistemology for Pre-apocalyptic Worlds

Why Pre-Apocalyptic?

Why Bayesian?

Why Post-anarchism?